

Economía Digital

Cinco lecturas complementarias para discusión guiada

Profesor titular: Dr. Leonardo González Tejeda
Curso: Economía Digital — ITESM Campus Santa Fe
Formato: Ensayos analíticos estilo *The Economist*, en español
Uso sugerido: Discusión guiada (Bloque aplicado de cada sesión)

- [1] Historia contemporánea de la economía digital
- [2] La burbuja *dot-com*: euforia, colapso y lecciones vigentes
- [3] Casos relevantes del ecosistema digital: Uber, Amazon, Mercado Libre y Netflix
- [4] ¿Qué tan grande es la economía digital? Tamaño actual y proyecciones a 2030
- [5] Inteligencia artificial y sesgo algorítmico
- [6] El economista como *Chief Digital Officer* en el contexto laboral de 2026

Índice

Lectura [1]: Historia contemporánea de la economía digital	2
Lectura [2]: La burbuja <i>dot-com</i>	8
Lectura [3]: Casos relevantes del ecosistema digital	14
Lectura [4]: Tamaño y proyecciones de la economía digital	20
Lectura [5]: IA y sesgo algorítmico	25
Lectura [6]: El economista como Chief Digital Officer	32

De ARPANET al agente de IA: medio siglo de economía digital

Cómo cinco oleadas tecnológicas reescribieron, una y otra vez, las mismas leyes económicas

TIEMPO DE LECTURA ESTIMADO: 20–22 MINUTOS

Cuando en octubre de 1969 un estudiante de la Universidad de California en Los Ángeles envió el primer mensaje a través de ARPANET –el sistema se cayó tras las dos primeras letras de la palabra “LOGIN”–, nadie en aquella sala imaginaba que sesenta años después una fracción no trivial del producto mundial se transaría a través de redes descendientes de ese experimento militar-académico. La historia de la economía digital no es la historia de un invento, sino la de *cinco oleadas superpuestas* de innovación –infraestructura, comercialización, plataformas, movilidad y, ahora, inteligencia artificial– en las que, sistemáticamente, la euforia tecnológica corrió por delante de la comprensión económica, para luego ser disciplinada por las mismas regularidades de costos, competencia y expectativas que Shapiro y Varian describieron para la “vieja” economía de redes. Esta lectura recorre esa historia en cinco actos y extrae, de cada uno, una lección que reaparecerá –con distinto disfraz– en las sesiones del curso.

Acto I (1969–1991): la red como bien público subsidiado

ARPANET, financiado por la Agencia de Proyectos de Investigación Avanzada de Defensa de Estados Unidos (DARPA), resolvió un problema de ingeniería –la conmutación de paquetes– pero también, sin proponérselo, sentó un precedente económico: durante dos décadas, la infraestructura de red se desarrolló como un bien cuasi público, financiado con presupuesto federal y operado por universidades, sin ánimo de lucro y sin mecanismo de precios. El protocolo TCP/IP, estandarizado en 1983, y el Sistema de Nombres de Dominio (DNS), creado en 1985, son –en el lenguaje de la Sesión 2 del curso– *bienes de infraestructura de red* cuyo valor depende directamente del número de participantes ($V(n) \sim n^2$, Ley de Metcalfe), pero cuya provisión inicial no podía sostenerse con financiamiento puramente privado dado que los rendimientos sociales excedían ampliamente los apropiables por cualquier firma individual –el clásico problema de subinversión en bienes con externalidades positivas no internalizadas.

Σ Nota técnica: por qué la red nació pública

La condición de bien no rival y parcialmente no excluible de la infraestructura de red temprana, combinada con economías de red crecientes en las primeras fases de adopción (región de pendiente positiva de $f(n^e)$ en la Figura 2 del *syllabus*), generaba una brecha entre el beneficio social marginal y el beneficio privado apropiable. El financiamiento público de ARPANET/NSFNET cerró esa brecha durante la fase de *masa subcrítica* ($n < n^*$), en la que ningún proveedor privado habría encontrado rentable construir la red por sí solo.

Acto II (1991–2000): la comercialización y el nacimiento del comercio electrónico

El punto de quiebre llegó en 1991, cuando la Fundación Nacional de Ciencia de Estados Unidos levantó la prohibición de uso comercial de su red troncal (NSFNET), y en 1993, cuando el navegador Mosaic –antecedente de Netscape– popularizó la interfaz gráfica de la *World Wide Web*, inventada por Tim Berners-Lee en 1989. La salida a bolsa de Netscape Communications en agosto de 1995 –con una

valuación que se duplicó el primer día de cotización pese a que la empresa aún no era rentable— es, retrospectivamente, el disparo de salida de la primera burbuja de valuación de la era digital (véase Lectura [2]). En este periodo nacen Amazon (1994), eBay (1995) y, en América Latina, Mercado Libre (1999): las tres empresas apostaron, cada una a su manera, a que los costos de transacción de *búsqueda*, *verificación* y *coordinación* —la taxonomía de Goldfarb y Tucker (2019) revisada en la Sesión 1— caerían lo suficiente como para sostener un modelo de intermediación puramente digital.




Figure 1: Usuarios de internet a nivel mundial, 1995–2024 (estimaciones ilustrativas con base en UIT / Our World in Data). La pendiente de la curva —no su nivel exacto— es el objeto de estudio: obsérvese la aceleración asociada a cada oleada tecnológica.

Acto III (2000–2007): la disciplina del mercado y el ascenso de la plataforma

El colapso del NASDAQ en marzo de 2000 (Lectura [2]) no detuvo la digitalización; la seleccionó. De la generación dot-com sobrevivieron —y prosperaron— las firmas cuyo modelo de negocio explotaba genuinas economías de escala y de red, no sólo el optimismo de los inversionistas. Es en esta década cuando se consolida la **plataforma multilateral** como arquitectura organizacional dominante: Google perfecciona la subasta de anuncios de búsqueda (2000–2002), Amazon lanza su *Marketplace* de terceros (2000) y, más adelante, Amazon Web Services (2006) —anticipando el negocio de infraestructura en la nube que hoy sostiene buena parte de sus márgenes—, y Facebook (2004) demuestra que las externalidades de red directas entre personas pueden monetizarse indirectamente vía un tercer lado del mercado: los anunciantes.

Acto IV (2007–2019): el teléfono como infraestructura y la economía gig

El lanzamiento del iPhone en 2007 y de la tienda de aplicaciones (*App Store*) en 2008 trasladó el punto de acceso a internet del escritorio al bolsillo, comprimiendo aún más los costos de *rastreo* y *verificación* de Goldfarb y Tucker: un teléfono con GPS, cámara y pago integrado permite verificar la identidad, ubicación y capacidad de pago de dos partes de una transacción a un costo marginal cercano a cero. Sobre esa infraestructura se edifica la economía *gig*: Uber (fundada en 2009) y Airbnb (2008) trasladan al consumidor la función de coordinación que antes desempeñaban centrales de taxis u operadores hoteleros, apoyándose en el aparato de mercados de dos lados que se formaliza en la Sesión 2 del curso (Rochet y Tirole, 2003). Netflix, fundada en 1997 como servicio de renta de DVD por correo,

migra a *streaming* en 2007 y –de forma crucial para el Tema 1 del curso– redefine su estructura de costos: de un negocio con costos logísticos variables no despreciables a uno con costo marginal de distribución prácticamente nulo.

“La tecnología cambia, pero las leyes de la economía permanecen.” Cada oleada –la web comercial, la plataforma, el teléfono inteligente, la inteligencia artificial– ha sido narrada, en su momento, como una ruptura total con el pasado. En cada caso, quienes sobrevivieron a la corrección posterior fueron los que entendieron mejor la estructura de costos y las externalidades de red subyacentes, no los que gritaron más fuerte que “esta vez es diferente”.

Acto V (2020–2026): pandemia, datificación e inteligencia artificial generativa

La pandemia de covid-19 (2020–2021) operó como un experimento natural de adopción forzada: el comercio electrónico, el trabajo remoto y el entretenimiento en *streaming* absorbieron, en cuestión de meses, una demanda que se proyectaba para varios años. Ese salto sentó las bases de la última –y todavía inconclusa– oleada: el lanzamiento público de modelos de lenguaje de gran escala (ChatGPT, noviembre de 2022) desplazó el centro de gravedad de la economía digital de la *intermediación de transacciones* a la *producción de predicciones* como insumo económico autónomo, en los términos que desarrolla el marco de Agrawal, Gans y Goldfarb (2018) y, más recientemente, Gans (2025) –materia central de la Sesión 4 de este curso.

Periodo	Hito tecnológico	Mecanismo económico dominante
1969–1991	ARPANET, TCP/IP, DNS	Provisión pública de infraestructura de red (externalidad no internalizable)
1991–2000	WWW comercial, Netscape, Amazon, eBay, Mercado Libre	Caída de costos de búsqueda y verificación; primera burbuja de valuación
2000–2007	Google Ads, AWS, Facebook	Consolidación de plataformas multilaterales y monetización indirecta
2007–2019	<i>iPhone, App Store, Uber, Airbnb, Netflix streaming</i>	Costos de coordinación casi nulos; economía <i>gig</i> ; costo marginal de distribución $\rightarrow 0$
2020–2026	Comercio electrónico pandémico, IA generativa	Predicción como insumo de producción económica autónomo

Table 1: Cinco oleadas de la economía digital y su mecanismo económico dominante.

Interludio: las guerras del navegador y el primer asalto antimonopolio digital

Antes de que existiera un debate sobre el poder de mercado de las plataformas de inteligencia artificial (Sesión 4, Tema 3.4), existió –casi treinta años antes– un debate estructuralmente idéntico sobre el navegador de internet. Netscape Navigator dominaba más del 80 % del mercado de navegación en 1995; Microsoft, temiendo que el navegador se convirtiera en una plataforma alternativa a Windows para ejecutar aplicaciones, integró Internet Explorer directamente en su sistema operativo de forma gratuita a partir de 1995 y firmó acuerdos de distribución exclusiva con fabricantes de computadoras. Para 1998, la cuota de mercado de Internet Explorer superaba a la de Netscape. El Departamento de Justicia de Estados Unidos demandó a Microsoft ese mismo año por prácticas monopólicas; en abril de

2000 –coincidiendo casi exactamente con el pico de la burbuja *dot-com* (Lectura [2])–, el juez Thomas Penfield Jackson dictaminó que Microsoft había violado la Ley Sherman mediante la vinculación (*tying*) ilegal de su navegador al sistema operativo. Aunque la sentencia de desmembramiento de la compañía fue revocada en apelación –el caso se resolvió en 2001 mediante un acuerdo de conducta, no de estructura–, el caso *United States v. Microsoft Corp.* estableció el precedente doctrinal central que hoy invocan tanto el Reglamento de Mercados Digitales europeo como la demanda de la Comisión Federal de Comercio de Estados Unidos contra Amazon (2023, revisada en la Lectura [3]): que el control de un punto de acceso dominante (un sistema operativo, un navegador, un mercado de aplicaciones) puede usarse para excluir a competidores en mercados adyacentes, incluso sin necesidad de que el precio al consumidor final suba –el criterio de daño al consumidor que dominó la política anti-monopolio estadounidense durante buena parte de las dos décadas siguientes, y que hoy se encuentra en revisión activa precisamente a la luz de casos como este.

La economía digital llega a América Latina: adopción tardía, salto móvil

La narrativa dominante de la historia digital –escrita mayoritariamente desde Silicon Valley– omite con frecuencia una trayectoria regional distinta y, en varios sentidos, más instructiva para este curso impartido en México: la de América Latina. A diferencia de Estados Unidos o Europa Occidental, la región llegó a la etapa de comercialización de internet (Acto II) con una penetración de telefonía fija históricamente baja –resultado, en gran medida, de mercados de telecomunicaciones protegidos y poco competidos hasta las privatizaciones y liberalizaciones de la década de 1990 (Telmex en México, 1990; Telebras en Brasil, 1998)–. Esa carencia de infraestructura de línea fija, lejos de ser sólo una desventaja, generó un patrón de **adopción telescópica** (*leapfrogging*): millones de hogares latinoamericanos pasaron directamente de no tener ningún servicio de telecomunicaciones a acceder a internet principalmente a través de teléfonos móviles, sin atravesar la fase intermedia de banda ancha fija que caracterizó la adopción estadounidense y europea entre 1995 y 2005.

Mercado Libre, fundada en Buenos Aires en 1999 por Marcos Galperin –en plena efervescencia *dot-com*, apenas meses antes del pico del NASDAQ–, sobrevivió a la corrección de 2000–2002 (Lectura [2]) en parte porque operaba en un mercado donde Amazon, eBay y otros competidores globales aún no tenían presencia significativa: Amazon no estableció operaciones formales de venta directa en Brasil sino hasta 2012 y en México hasta 2015, más de una década después de que Mercado Libre hubiera consolidado su posición de plataforma dominante regional. La lección –relevante para la Sesión 2 del curso– es que la masa crítica de una red (Figura 2 del *syllabus*) no es una propiedad universal de la tecnología, sino una propiedad *local*: el mismo mecanismo de expectativas cumplidas de Katz y Shapiro (1985) que explica el dominio de Amazon en Estados Unidos explica, con igual fuerza formal, el dominio de Mercado Libre en América Latina, precisamente porque cada red alcanzó su masa crítica regional antes de que un competidor global pudiera desplazarla.

La segunda ola relevante para la región llegó con la expansión de las redes móviles de banda ancha (3G desde 2009–2011, 4G desde 2015 en adelante) y la consecuente democratización del *smartphone*, que habilitó –entre 2015 y 2020– el auge de la economía *gig* regional (Uber llegó a México en 2013, a Brasil en 2014) y de la tecnología financiera (*fintech*): Nubank, fundada en Brasil en 2013, y Mercado Pago, escindida como unidad de negocio independiente de Mercado Libre en esos mismos años, atacaron un problema estructural de la región –niveles de bancarización históricamente bajos– con el mismo argumento de abaratamiento de la predicción crediticia que se revisa formalmente en la Sesión 4 (véase también la Lectura [3] sobre Mercado Libre). La pandemia de covid-19 aceleró, en la región, una convergencia parcial con los niveles de penetración de comercio electrónico de economías avanzadas –México pasó de una participación del comercio electrónico en el PIB de apenas 3.0 % en 2013 a 5.9 % en 2022, según el Valor Agregado Bruto del Comercio Electrónico del INEGI–, aunque la brecha de

infraestructura logística y de acceso a crédito formal documentada por UNCTAD (Lectura [4]) sigue siendo, tres décadas después del nacimiento de la red comercial, una diferencia estructural persistente entre el centro y la periferia de la economía digital mundial.

Acto V, en detalle: la velocidad sin precedente de la adopción de la IA generativa

Vale la pena detenerse en la magnitud de la última oleada. ChatGPT, lanzado el 30 de noviembre de 2022, alcanzó –según estimaciones ampliamente citadas de la propia OpenAI y de analistas de mercado– cien millones de usuarios activos mensuales en un plazo de dos meses, una velocidad de adopción sin precedente comparable entre los productos de consumo digital previamente revisados en esta lectura: Instagram tardó aproximadamente dos años y medio en alcanzar esa cifra; TikTok, considerado hasta entonces el producto de más rápida adopción de la historia, tardó alrededor de nueve meses. Esa velocidad de adopción –que en el lenguaje formal de la Sesión 2 equivale a una curva $f(n^e)$ inusualmente pronunciada, con un umbral de masa crítica n^* alcanzado casi instantáneamente– desató, entre 2023 y 2026, una carrera de inversión de capital entre un número reducido de laboratorios de investigación y proveedores de infraestructura de cómputo a gran escala (Sesión 4, sobre la estructura de costos de la predicción algorítmica), cuya dinámica de financiamiento –y sus paralelismos con la burbuja *dot-com*– se examina con detalle en la Lectura [2] de este cuadernillo.

El motor silencioso: la caída del costo del cómputo

Ninguna de las cinco oleadas descritas en esta lectura habría sido posible sin una regularidad empírica que rara vez ocupa el centro de la narrativa histórica, pero que subyace a cada una de ellas: la caída sostenida –de varios órdenes de magnitud a lo largo de seis décadas– del costo por unidad de capacidad de cómputo y almacenamiento, popularizada como “Ley de Moore” a partir de la observación de Gordon Moore en 1965 sobre la duplicación periódica del número de transistores por circuito integrado. Esta regularidad –que en rigor es una tendencia de ingeniería e inversión de capital, no una ley física– es, en el lenguaje formal de la Sesión 1 del *syllabus*, el mecanismo que sostiene la caída persistente de c^* (el costo marginal de los bienes digitales) a lo largo de todo el periodo analizado: es la razón última por la que ARPANET pudo escalar de unos pocos nodos universitarios a una red comercial de miles de millones de usuarios sin que el costo unitario de procesar y transmitir información creciera proporcionalmente, y es –de forma directa– la razón por la que entrenar un modelo de inteligencia artificial de frontera es hoy computacionalmente viable a una escala que habría sido económicamente prohibitiva incluso una década atrás. Cuando en la Sesión 4 del curso se analice la estructura de costos de la predicción algorítmica (F_{IA} alto, $c_{IA} \rightarrow 0$), conviene recordar que no se trata de una estructura de costos nueva o específica de la inteligencia artificial, sino de la manifestación más reciente de la misma tendencia de fondo que ha definido –con distinto ropaje tecnológico– cada una de las cinco oleadas de esta historia.

La lección que se repite

Vista en retrospectiva, la historia contemporánea de la economía digital no es lineal sino *recurrente*: cada oleada reabre el mismo debate –¿estamos ante una ruptura de las leyes económicas o ante una nueva manifestación de las de siempre?– y, en cada ocasión, la evidencia posterior favorece la segunda lectura. La infraestructura pública cede paso a la privada cuando la masa crítica se alcanza (Sesión 2); los costos de transacción caen y desplazan la frontera de Coase entre mercado y firma (Sesión 1); las plataformas ganan poder de mercado por la combinación de economías de escala y de red (Sesión 2); y, hoy, la inteligencia artificial abarata un insumo –la predicción– con la misma lógica de costo medio decreciente que ya vimos en los bienes de información clásicos (Sesión 4). Entender esta historia no es un ejercicio de anticuario: es la mejor defensa contra el error –tan costoso como recurrente– de creer

que la tecnología de turno ha suspendido la escasez, la competencia o los rendimientos decrecientes.

Bibliografía

Abbate, J. (1999). *Inventing the Internet*. MIT Press.

Castells, M. (2001). *The Internet Galaxy: Reflections on the Internet, Business, and Society*. Oxford University Press.

Cortada, J. W. (2020). *IBM: The Rise and Fall and Reinvention of a Global Icon*. MIT Press.

Goldfarb, A., y Tucker, C. (2019). Digital Economics. *Journal of Economic Literature*, 57(1), 3–43.

Greenstein, S. (2015). *How the Internet Became Commercial: Innovation, Privatization, and the Birth of a New Network*. Princeton University Press.

International Telecommunication Union (UIT). *Facts and Figures: Measuring Digital Development* (series histórica). <https://www.itu.int>

Isaacson, W. (2014). *The Innovators: How a Group of Hackers, Geniuses, and Geeks Created the Digital Revolution*. Simon & Schuster.

Mueller, M. (2002). *Ruling the Root: Internet Governance and the Taming of Cyberspace*. MIT Press.

Roser, M., Ritchie, H., y Ortiz-Ospina, E. *Internet*. Our World in Data. <https://ourworldindata.org/internet>

Zittrain, J. (2008). *The Future of the Internet — And How to Stop It*. Yale University Press.

La resaca de 2000: anatomía de la burbuja *dot-com*

Y por qué sus preguntas incómodas siguen siendo las correctas para juzgar el auge de la inteligencia artificial

TIEMPO DE LECTURA ESTIMADO: 20–22 MINUTOS

El 10 de marzo de 2000, el índice NASDAQ Composite cerró en 5,048.62 puntos, un nivel 572 % superior al de enero de 1995. Dieciocho meses después, ese mismo índice había perdido el 78 % de su valor, tocando fondo en 1,114 puntos el 4 de octubre de 2002 –una destrucción de riqueza bursátil superior a los cinco billones de dólares (*trillion*, en la nomenclatura anglosajona). El NASDAQ tardaría quince años en recuperar su máximo de marzo de 2000. La burbuja *dot-com* es, con frecuencia, contada como una anécdota moralizante sobre la codicia; para un curso de economía digital resulta más útil como un **caso de estudio riguroso** sobre cómo la microeconomía de los bienes de información –precisamente la que estudiamos en la Sesión 1– puede quedar temporalmente eclipsada por la psicología de mercado, y sobre cómo, tarde o temprano, reafirma su vigencia.

La anatomía de la euforia

Tres ingredientes, actuando en conjunto, alimentaron la burbuja:

1. **Una narrativa de ruptura estructural.** La proposición –parcialmente correcta– de que internet reduciría permanentemente los costos de transacción (Sesión 1) se extendió, sin fundamento, a la conclusión de que las métricas tradicionales de rentabilidad habían quedado obsoletas. Métricas alternativas como el número de visitantes únicos (*eyeballs*) o el “quemado” mensual de caja financiado con capital de riesgo sustituyeron, en la valuación de muchas firmas, al flujo de caja descontado.
2. **Financiamiento abundante y barato.** La Reserva Federal mantuvo tasas de interés históricamente bajas hasta 1999, cuando inició un ciclo de seis alzas consecutivas entre 1999 y mediados de 2000 –el detonante convencionalmente citado del colapso–. El capital de riesgo, atraído por rendimientos de las OPI (ofertas públicas iniciales) que en 1999 promediaron ganancias de tres dígitos porcentuales el primer día de cotización, financió modelos de negocio que privilegiaban la adquisición agresiva de usuarios (*growth at all costs*) sobre la rentabilidad unitaria.
3. **Retroalimentación reflexiva entre precio y entrada.** Cada OPI exitosa validaba, a ojos de los inversionistas, el modelo de negocio de la siguiente cohorte de empresas –un mecanismo que Perez (2002) describe como característico de toda “revolución tecnológica”: una fase de instalación especulativa que antecede a la fase de despliegue productivo.

Los sobrevivientes silenciosos

Es fácil, al narrar una burbuja, concentrarse en los fracasos estridentes –Pets.com, Webvan, Boo.com– y olvidar que buena parte de las empresas que hoy dominan la economía digital atravesaron exactamente la misma corrección bursátil sin desaparecer, aunque con cicatrices considerables. Cisco Systems, el proveedor de infraestructura de red que se convirtió, en marzo de 2000, en la empresa más valiosa del mundo por capitalización de mercado –superando incluso a Microsoft y General Electric–, vio caer el precio de su acción más del 80 % entre 2000 y 2002; tardaría más de dos décadas en volver a acercarse a su máximo histórico de aquel año. Priceline.com, el sitio de subastas de tarifas de viaje




Figure 2: Trayectoria estilizada del índice NASDAQ Composite, 1995–2003 (valores de cierre aproximados en puntos de referencia anual/trimestral).

que llegó a perder 97 % de su valor de mercado durante el año 2000, sobrevivió –a diferencia de la mayoría de sus pares– gracias a que, tras la corrección, reorientó su modelo de negocio hacia la venta directa de reservaciones de hotel con márgenes más predecibles; renombrada Booking Holdings, es hoy una de las mayores empresas de viajes en línea del mundo. eBay, que nunca dependió de publicidad especulativa para su modelo de ingresos –cobraba comisiones directas sobre transacciones reales desde su fundación en 1995–, mantuvo rentabilidad operativa incluso durante el peor momento de la corrección. El patrón común entre estos tres sobrevivientes –y el propio caso de Amazon, revisado más arriba– es que ninguno dependía, para su viabilidad financiera, de que el mercado de capitales permaneciera dispuesto a financiar pérdidas operativas de forma indefinida: los tres generaban, o estaban a poca distancia de generar, flujo de caja operativo positivo antes de que ese financiamiento se cerrara abruptamente en 2000–2001. Es la misma prueba de estrés –¿puede la empresa sobrevivir sin acceso continuo a financiamiento externo barato?– que muchos analistas aplican hoy, con explícita referencia a esta historia, a las empresas que lideran el actual ciclo de inversión en infraestructura de inteligencia artificial.

El error más común al narrar la burbuja *dot-com* es tratarla como una prueba de que “internet estaba sobrevalorado”. Una lectura más precisa –y más útil para este curso– es que el mercado *sobrevaloró indiscriminadamente*, sin distinguir entre firmas con genuinas economías de escala/red y firmas sin ellas, y que la corrección de 2000–2002 operó como un mecanismo de selección que sí hizo esa distinción *ex post*.

• Caso: Pets.com frente a Amazon

Pets.com recaudó cerca de 300 millones de dólares en su OPI de febrero de 2000 y, incapaz de generar margen positivo por unidad vendida –el costo de enviar alimento para mascotas, pesado y de bajo margen, no exhibía la estructura de costo marginal casi nulo de un bien digital–, cerró operaciones en noviembre del mismo año: su capitalización de mercado pasó de más de 300 millones de dólares a cero en menos de un año. Amazon, que en 2000 cotizaba con pérdidas operativas crecientes y fue ampliamente criticada por analistas escépticos, sobrevivió a la corrección –su acción llegó a caer más del 90 % desde su máximo– porque, a diferencia de Pets.com,

su modelo apostaba genuinamente a economías de escala logísticas y, más adelante, a Amazon Web Services (2006), un negocio de infraestructura con estructura de costos –alto costo fijo, costo marginal decreciente– idéntica a la revisada en la Sesión 1 del curso.

Los números del delirio: cuánto costaba no tener ganancias

Para apreciar la magnitud de la desconexión entre precio y fundamentales durante 1999–2000 conviene examinar cifras concretas, no sólo la trayectoria del índice agregado. En 1999 salieron a bolsa 457 empresas tecnológicas en Estados Unidos –una cifra que no volvería a repetirse en dos décadas–, con una ganancia promedio del primer día de cotización cercana al 70 %. El caso extremo fue VA Linux Systems, cuya acción se disparó 698 % el día de su OPI en diciembre de 1999, la mayor ganancia de primer día jamás registrada hasta entonces en una bolsa estadounidense. Dado que la inmensa mayoría de estas empresas carecía de utilidades –y, con frecuencia, de ingresos significativos–, los analistas sustituyeron el múltiplo precio-utilidad convencional por métricas alternativas como el múltiplo precio-ventas o, en ausencia incluso de ventas relevantes, el número de visitantes únicos mensuales (*eyeballs*) como sustituto de valor. La velocidad a la que estas empresas consumían el capital recaudado –su *tasa de quema* (*burn rate*)– se convirtió en una métrica de riesgo tan seguida como cualquier indicador de rentabilidad: numerosas firmas del periodo agotaban su capital en menos de doce meses, obligándolas a regresar al mercado –o a la quiebra– antes de haber probado la viabilidad de su modelo de negocio. La ostentación publicitaria de ese exceso de capital alcanzó su punto culminante en el Super Bowl XXXIV de enero de 2000, cuando diecisiete empresas *dot-com* pagaron aproximadamente 2.2 millones de dólares cada una por 30 segundos de publicidad –varias de ellas cesarían operaciones antes de que concluyera ese mismo año.

Webvan y Boo.com: cuando el software no sustituye a la logística

Dos fracasos ilustran, con especial nitidez, el error de diagnóstico económico más común de la época: confundir la caída del costo marginal de *distribuir información* (el argumento correcto de Shapiro y Varian para bienes digitales) con una caída equivalente del costo marginal de *distribuir bienes físicos* (un argumento que la Sesión 1 del curso permite refutar formalmente).

• Caso: Webvan, la logística que el capital no pudo comprar

Webvan recaudó 375 millones de dólares en su oferta pública inicial de noviembre de 1999 con la promesa de revolucionar la venta de abarrotes mediante entrega a domicilio respaldada por almacenes automatizados de última generación –una inversión de capital fijo que, para 2001, superaba los 1,000 millones de dólares en construcción de infraestructura logística propia en más de una decena de ciudades estadounidenses. El problema, visto desde la Sesión 1 del *syllabus*, es que un abarrote –a diferencia de un archivo digital– no tiene costo marginal de reproducción cercano a cero: cada entrega requería un vehículo, un conductor y un margen de tiempo de por sí estrecho en un negocio de márgenes brutos históricamente bajos (2–3 % en el comercio de abarrotes tradicional). Webvan se declaró en quiebra en julio de 2001, apenas dos años después de su fundación. La ironía histórica es que el modelo que sí funcionaría –Instacart, fundado en 2012– resolvió exactamente el problema de costos fijos que hundió a Webvan: en lugar de construir almacenes propios, utilizó la infraestructura logística ya existente de supermercados establecidos y una fuerza de trabajo bajo demanda (economía *gig*, Acto IV de la Lectura [1]), evitando así la inversión de capital fijo que Webvan sí tuvo que asumir.

• Caso: Boo.com y el descalce entre infraestructura de red y ambición de producto

La empresa británica de moda en línea Boo.com gastó aproximadamente 135 millones de dólares de capital de riesgo en dieciocho meses –gran parte en una campaña de mercadotecnia paneuropea simultánea en varios idiomas– para lanzar, en 1999, un sitio web construido casi enteramente en Flash, con modelos tridimensionales rotantes de cada prenda. El sitio tardaba varios minutos en cargar sobre las conexiones de acceso telefónico (*dial-up*) que aún dominaban el acceso residencial a internet en Europa en esa fecha. Boo.com cerró operaciones en mayo de 2000. El caso ilustra un error distinto –pero complementario– al de Webvan: mientras Webvan subestimó el costo marginal físico de su producto, Boo.com sobrestimó la infraestructura de red disponible del lado de la demanda, diseñando un producto cuya experiencia de usuario era incompatible con la tecnología de acceso mayoritaria de su mercado objetivo.

La resaca macroeconómica y regulatoria

El colapso bursátil no fue un fenómeno contenido al sector tecnológico. Contribuyó a una recesión económica estadounidense –moderada mas no trivial, de ocho meses de duración según la datación oficial de la Oficina Nacional de Investigación Económica (NBER)– entre marzo y noviembre de 2001, agravada por los atentados del 11 de septiembre de ese año. El financiamiento de capital de riesgo, que había alcanzado niveles históricos en 2000, se contrajo de forma abrupta durante los tres años siguientes –una caída que la industria de capital de riesgo describiría después como la más severa de su historia hasta entonces–, y el mercado de ofertas públicas iniciales tecnológicas permaneció prácticamente cerrado durante buena parte de 2001 y 2002. En el plano regulatorio, la cadena de escándalos contables que se destapó en paralelo al desplome bursátil –Enron (diciembre de 2001) y WorldCom (junio de 2002), esta última en sí misma una empresa de telecomunicaciones sobreexpandida durante la fiebre de infraestructura de fibra óptica de finales de los noventa– condujo a la promulgación de la Ley Sarbanes-Oxley en 2002, que endureció de forma permanente los requisitos de gobierno corporativo y auditoría financiera para empresas que cotizan en bolsa en Estados Unidos, incluyendo, por supuesto, a la siguiente generación de empresas digitales que saldría a bolsa a partir de 2004 (Google) en un entorno regulatorio sustancialmente más exigente.

Es tentador, en 2026, trazar un paralelismo directo entre la burbuja *dot-com* y el actual ciclo de inversión en infraestructura de inteligencia artificial. El paralelismo es parcialmente válido y parcialmente engañoso, y precisar la diferencia es un ejercicio útil de estática comparativa institucional:

La pregunta que la burbuja *dot-com* nos enseña a formular no es “¿es exagerado el entusiasmo actual?” –pregunta que rara vez admite una respuesta objetiva *ex ante*–, sino la más disciplinada: ¿*genera el gasto de capital actual un activo con estructura de costos que sostenga rentas por encima del costo de capital una vez agotado el efecto novedad?* Es precisamente la pregunta que Shapiro y Varian (2000) –y, dos décadas después, Gans (2025)– nos entrenan para formular con rigor microeconómico en lugar de intuición de mercado.

El colapso del NASDAQ no demostró que Internet fuera una moda pasajera; demostró que *no toda* empresa que usa Internet posee, por ese solo hecho, una estructura de costos o una posición competitiva defendible. La misma disciplina se aplicará, tarde o temprano, a la ola actual de inversión en inteligencia artificial.

Dimensión	Burbuja <i>dot-com</i> (1998–2000)	Ciclo de inversión en IA (2023–2026)
Financiamiento del <i>capex</i>	Predominantemente deuda corporativa y capital de riesgo externo; muchas firmas sin ingresos operativos	Predominantemente flujo de caja operativo de firmas ya rentables (p. ej., <i>capex</i> de infraestructura de IA de Amazon, del orden de 130,000 millones de dólares en 2025, financiado en gran medida con caja operativa)
Naturaleza del activo sobreinvertido	Fibra óptica y capacidad de red frecuentemente redundante entre competidores	Centros de datos y capacidad de cómputo con demanda medible de inferencia, aunque con riesgo de sobrecapacidad si la demanda no converge con la oferta proyectada
Modelo de ingresos de las firmas líderes	Con frecuencia ausente o especulativo (<i>eyeballs</i> , no ingresos)	Presente y creciente, aunque la relación entre inversión y monetización de la IA generativa todavía se está probando
Concentración de beneficiarios	Amplia dispersión de firmas emergentes sin defensas competitivas claras	Alta concentración en un número reducido de proveedores de cómputo, modelos y nube (estructura de costos revisada en la Sesión 4 del <i>syllabus</i>)

Table 2: Paralelismos y diferencias entre el ciclo de inversión *dot-com* y el ciclo de inversión en infraestructura de inteligencia artificial.

Ejercicio de discusión guiada

Preguntas para el bloque aplicado

(i) Con base en la estructura de costos revisada en la Sesión 1 (F^* alto, $c^* \rightarrow 0$), clasifique tres empresas *dot-com* fallidas (Webvan, Boo.com, eToys) según si su modelo de negocio exhibía genuinamente esa estructura o si, por el contrario, dependía de una logística física con costos marginales positivos apreciables. (ii) Aplicando el mismo criterio, ¿qué firmas del actual ciclo de infraestructura de IA le parecen mejor posicionadas para sostener rentas una vez normalizado el gasto de capital, y cuáles le parecen más expuestas a un ajuste de valuación?

Bibliografía

Cassidy, J. (2002). *Dot.con: The Greatest Story Ever Sold*. HarperCollins.

Goldfarb, B., Kirsch, D., y Miller, D. A. (2007). Was There Too Little Entry During the Dot Com Era? *Journal of Financial Economics*, 86(1), 100–144.

Ljungqvist, A., y Wilhelm, W. J. (2003). IPO Pricing in the Dot-com Bubble. *Journal of Finance*, 58(2), 723–752.

Ofek, E., y Richardson, M. (2003). DotCom Mania: The Rise and Fall of Internet Stock Prices. *Journal*

of Finance, 58(3), 1113–1137.

Perez, C. (2002). *Technological Revolutions and Financial Capital: The Dynamics of Bubbles and Golden Ages*. Edward Elgar.

Shiller, R. J. (2000). *Irrational Exuberance*. Princeton University Press.

Federal Reserve Bank of St. Louis (FRED). *NASDAQ Composite Index*, serie histórica. <https://fred.stlouisfed.org>

Cuatro maneras de ganar dinero en la economía digital

Uber, Amazon, Mercado Libre y Netflix aplican –cada una a su manera– las mismas leyes de la Sesión 2 del curso

TIEMPO DE LECTURA ESTIMADO: 22–24 MINUTOS

Ningún libro de texto sustituye la disciplina de observar cómo cuatro empresas que compiten en industrias completamente distintas –transporte urbano, comercio minorista, comercio electrónico latinoamericano y entretenimiento en video– llegan, por caminos distintos, al mismo repertorio de mecanismos económicos: precios estructurados en dos lados del mercado, integración vertical selectiva, versionado de productos y explotación de economías de escala del lado de la oferta. Esta lectura examina cada una a través del lente formal desarrollado en las Sesiones 1 a 3 del curso.

Empresa	Ingresos 2025	Cap. de mercado (2026) ^a	Empleados	Mecanismo económico central
Amazon	\$716,900 M	~\$2.3–2.9 billones	~1.58 M	Integración vertical (<i>flywheel</i>), economías de alcance en datos/cómputo (AWS)
Uber	\$52,020 M	~\$143–146 mil M	~34,000 ^b	Mercado de dos lados con precios dinámicos (<i>surge pricing</i>)
Mercado Libre	\$28,890 M	~\$91–95 mil M	~20,300	Integración <i>marketplace</i> + <i>fin-tech</i> (Mercado Pago) en mercados con baja bancarización
Netflix	\$45,180 M	~\$298–300 mil M	~16,000	Versionado y discriminación de precios de segundo grado (niveles de suscripción)

Table 3: Comparativo de las cuatro empresas caso (cifras aproximadas, año fiscal 2025 / capitalización de mercado a mediados de 2026). ^a La capitalización de mercado fluctúa diariamente; se reporta un rango observado. ^b Excluye conductores y repartidores, clasificados como contratistas independientes –precisamente el punto de discusión regulatoria revisado más adelante.

Uber: precios de dos lados en tiempo real

Uber conecta dos grupos –pasajeros y conductores– con externalidades indirectas mutuas: un pasajero valora más la aplicación cuanto mayor es la disponibilidad de conductores cercanos ($\partial u_B / \partial n_S > 0$), y un conductor valora más la plataforma cuanto mayor es la densidad de solicitudes ($\partial u_S / \partial n_B > 0$). El *surge pricing* –el ajuste de tarifas en tiempo real ante desequilibrios entre oferta y demanda geolocalizada– es, en el lenguaje de la Sesión 2, un mecanismo de **ajuste dinámico de la estructura de precios de Armstrong (2006)**: cuando la demanda de pasajeros supera momentáneamente a la oferta de conductores en una zona, la plataforma eleva p_B (y la compensación efectiva a S) para inducir una reasignación de oferta hacia esa zona, restaurando el equilibrio de mercado más rápido de lo que permitiría un precio fijo regulado. Uber reportó su primer año con utilidad neta bajo normas contables estadounidenses (GAAP) de forma consistente en 2023, tras más de una década de pérdidas




Figure 3: Ingresos anuales 2025 de las cuatro empresas caso (escala logarítmica implícita en la disparidad de magnitudes; Amazon opera, ante todo, como conglomerado de infraestructura digital, no sólo como *e-commerce*).

operativas financiadas con capital de riesgo –una travesía que ilustra el tiempo que puede tomar a una plataforma alcanzar la masa crítica (n^* en la Figura 2 del *syllabus*) en múltiples mercados geográficos simultáneamente.

El principal frente regulatorio de la compañía –la clasificación laboral de conductores como contratistas independientes frente a empleados– no es una disputa marginal, sino una disputa sobre quién absorbe el costo de los insumos no salariales (seguridad social, prestaciones, seguro de desempleo) en un modelo cuya estructura de costos depende, en buena medida, de mantener esa flexibilidad contractual. En febrero de 2021, la Corte Suprema del Reino Unido falló, en el caso *Uber BV v. Aslam*, que los conductores de la plataforma debían clasificarse como “trabajadores” (*workers*, una categoría intermedia del derecho laboral británico) con derecho a salario mínimo y vacaciones pagadas –un fallo que, extendido a otras jurisdicciones, elevaría estructuralmente el costo marginal por viaje de la plataforma, alterando directamente el diferencial $p_S - c_S$ de la estructura de precios de Armstrong revisada en la Sesión 2. La compañía ha respondido con una estrategia de diversificación geográfica de riesgo regulatorio –expandiéndose agresivamente hacia mercados con marcos laborales más flexibles– y de expansión hacia negocios adyacentes (reparto de comida, viajes y, más recientemente, acuerdos de distribución con plataformas de viajes como Expedia), un patrón de **envolvimiento de plataforma** (Sesión 3, Eisenmann, Parker y Van Alstyne, 2011) que aprovecha su base instalada de usuarios y su infraestructura de pagos y geolocalización ya amortizada.

Amazon: el *flywheel* y la economía de alcance

Amazon ilustra, mejor que ninguna otra firma del listado, el concepto de economías de alcance ($C(q_1 + q_2) < C(q_1) + C(q_2)$) revisado en la Sesión 3. Su “rueda volante” (*flywheel*) –la idea, atribuida a Jeff Bezos, de que menores precios atraen más clientes, lo que atrae más vendedores externos, lo que amplía la selección, lo que a su vez atrae más clientes– describe informalmente el mismo mecanismo de retroalimentación positiva formalizado en la Figura 2 del *syllabus* para redes de usuarios. Pero el caso

más instructivo para la Sesión 3 es AWS: una capacidad interna de cómputo distribuido, construida originalmente para sostener las operaciones de pico estacional del comercio minorista, se convirtió en un negocio independiente que hoy concentra –pese a representar una fracción minoritaria de los ingresos totales de la compañía (en el entorno del 15–18 %)– una parte desproporcionadamente alta de la utilidad operativa consolidada: en el primer trimestre de 2025, por ejemplo, AWS generó cerca de 11,500 millones de dólares de utilidad operativa sobre 29,300 millones de ingresos –un margen operativo superior al 39 %–, muy por encima del margen consolidado de la compañía en su conjunto. La lección de organización industrial es clara: la especificidad de un activo de infraestructura computacional resultó *menos* idiosincrática de lo previsto –y por tanto más rentable de vender a terceros– que la especificidad de los datos de comportamiento del consumidor, que Amazon mantiene estrictamente internalizados.

En septiembre de 2023, la Comisión Federal de Comercio de Estados Unidos, junto con diecisiete fiscalías estatales, demandó a Amazon por prácticas monopólicas, alegando –entre otros cargos– que la plataforma penaliza algorítmicamente a los vendedores externos que ofrecen precios más bajos en sitios rivales (una práctica de *anti-discounting*) y que condiciona la visibilidad preferente en los resultados de búsqueda (la “Buy Box”) a la contratación de sus propios servicios de logística –una forma de autopreferencia estructuralmente análoga a la vinculación de Internet Explorer a Windows que motivó el caso *Microsoft* de 1998 (Lectura [1]). El desenlace del litigio –en curso al momento de escribir esta lectura– será, casi con certeza, la referencia doctrinal central para la próxima década de política de competencia aplicada a plataformas digitales verticalmente integradas, y una lectura obligada para cualquier discusión de la Sesión 4 del curso sobre regulación de mercados digitales concentrados.

Mercado Libre: plataforma y fintech en un mercado de baja bancarización

Mercado Libre –fundada en 1999 en Buenos Aires y hoy con sede corporativa en Montevideo– ofrece el contraste latinoamericano más relevante con Amazon. Su crecimiento reciente –ingresos de 28,890 millones de dólares en 2025, un 39 % más que en 2024, con 27 trimestres consecutivos de crecimiento superior al 30 % interanual– se explica en gran medida por la integración vertical de **Mercado Pago**, su brazo de tecnología financiera, cuyo volumen total de pagos alcanzó más de 71,000 millones de dólares en el tercer trimestre de 2025 (un 41 % más interanual). Esta integración resuelve, en mercados con niveles de bancarización históricamente bajos, un problema de información asimétrica análogo al de Akerlof (Sesión 2, 2.3): sin acceso extendido a historiales crediticios formales, la plataforma utiliza sus propios datos transaccionales –generados por la actividad de compraventa en el *marketplace*– para suscribir crédito a comerciantes y consumidores que un banco tradicional no podría evaluar con la misma precisión ni el mismo costo. Es, en esencia, una aplicación regional del argumento de la Sesión 4 sobre la IA como abaratamiento de la predicción: Mercado Libre convierte datos de comportamiento en predicciones de riesgo crediticio a un costo marginal muy inferior al de la banca tradicional.

• Caso: la integración fintech como respuesta a un fallo de mercado

En 2024, la cartera de crédito de Mercado Libre creció aceleradamente en Brasil y México; para 2025–2026 la compañía anunció una inversión récord –superior a 4,600 millones de dólares sólo para México en 2026– destinada a logística, tecnología y expansión de servicios financieros. Discuta en clase: ¿en qué medida esta estrategia reproduce, en clave latinoamericana, el argumento de integración vertical por especificidad de datos revisado para AWS? ¿Qué riesgos de concentración de mercado –y de exposición macropudencial, dado el crecimiento del libro de crédito– introduce esta integración?

Netflix: versionado como discriminación de precios de segundo grado

Netflix ofrece la aplicación más nítida, entre las cuatro empresas caso, del concepto de **versionado** revisado en la Sesión 1 a partir de Varian (1997/2000) y citado en la propia reseña de Shapiro y Varian que abre el *syllabus* del curso (“*versionar* un producto de información [permite] venderlo a diferentes segmentos del mercado a precios diferentes”). La introducción, en 2022, de un nivel de suscripción con publicidad –a un precio significativamente menor que el nivel estándar sin anuncios– es un ejemplo textbook de discriminación de precios de segundo grado: la plataforma no puede observar directamente la disposición a pagar de cada usuario, pero diseña un menú de opciones (calidad de video, número de pantallas simultáneas, presencia de publicidad) que induce la autoselección de los consumidores según su valoración marginal del atributo “ausencia de anuncios”.

La política de restricción del uso compartido de contraseñas fuera del hogar, implementada globalmente entre 2023 y 2024, ilustra además cómo una plataforma de bien de información puede usar datos de uso (direcciones IP, patrones de dispositivo) para hacer cumplir una segmentación de precios que, de otro modo, sería imposible de sostener dado el costo marginal de distribución cercano a cero de una transmisión adicional –exactamente el problema de apropiabilidad que anticipaban Shapiro y Varian (2000) para cualquier bien no rival–. El resultado comercial fue inmediato: Netflix reportó la adición de casi nueve millones de suscriptores netos en el trimestre siguiente al anuncio de la medida en Estados Unidos (mayo de 2023), y la compañía cerró 2025 con ingresos de 45,180 millones de dólares –un 16 % más que en 2024– y un margen neto superior al 28 %, uno de los más altos entre las cuatro empresas caso, reflejo directo de una estructura de costos dominada por gasto de contenido (un costo mayoritariamente fijo por título, amortizable sobre una base de suscriptores creciente) más que por costos variables de distribución.

Lo que no vemos: por qué no hay una quinta gran plataforma

Una pregunta que rara vez se formula explícitamente, pero que resulta instructiva desde la óptica de las Sesiones 1 y 2 del curso, es por qué el ecosistema digital latinoamericano –pese a contar con Mercado Libre como plataforma de comercio electrónico y fintech de escala regional (véase también el Acto V de la Lectura [1])– no ha producido un competidor doméstico de escala comparable en transporte urbano o en entretenimiento por *streaming*, segmentos donde Uber y Netflix, ambas de origen estadounidense, dominan la región casi sin contrapeso local. La respuesta formal remite directamente a la Figura 2 del *syllabus*: la masa crítica n^* de una red de transporte urbano o de un catálogo de contenido audiovisual es, en gran medida, *independiente de la geografía de origen del capital que la financia* –a diferencia del comercio electrónico y los pagos digitales, donde la confianza local, el conocimiento regulatorio específico de cada país y la integración con métodos de pago informales (efectivo, transferencias bancarias domésticas) confirieron a Mercado Libre una ventaja de primer movimiento defendible durante la década crítica de 2000 a 2010–. Uber y Netflix, en cambio, competían desde el inicio con un producto esencialmente estandarizable a nivel global –un algoritmo de emparejamiento de viajes o un catálogo de contenido con costos de producción amortizables sobre una base de suscriptores mundial–, de forma que la ventaja de escala global de capital y de datos de entrenamiento superó, en esos segmentos específicos, cualquier ventaja de conocimiento local que un competidor regional pudiera ofrecer. Es una ilustración precisa –y con implicaciones directas de política industrial para la región– de que la estructura de costos de un bien digital (Sesión 1) determina, con frecuencia, si la ventaja competitiva relevante es *local* o *global*, mucho antes de que cualquier consideración de talento, capital de riesgo disponible o política pública entre en juego.

Una nota sobre estructura laboral: empleados formales frente a fuerza de trabajo de plataforma

La comparación de la Tabla 3 esconde una asimetría que merece discusión explícita: la cifra de “empleados” reportada por cada empresa mide conceptos radicalmente distintos según el modelo de negocio subyacente. Los 34,000 empleados de Uber son, casi en su totalidad, personal corporativo –ingeniería, operaciones, atención al cliente–; los varios millones de conductores y repartidores que generan la totalidad de los ingresos operativos de la plataforma no aparecen en esa cifra, precisamente porque su estatus de contratistas independientes es la variable de decisión estratégica central revisada líneas arriba. Amazon, en el extremo opuesto, reporta 1.58 millones de empleados directos –la gran mayoría personal de almacén y logística de última milla, con relativamente poca externalización hacia contratistas independientes en su operación central de comercio minorista, aunque sí utiliza extensamente contratistas de reparto de última milla (*delivery service partners*) organizados como pequeñas empresas independientes–. Mercado Libre y Netflix se ubican en un punto intermedio de esta escala: ambas mantienen plantillas relativamente reducidas (20,300 y 16,000 empleados, respectivamente) en relación con sus ingresos, reflejo de modelos de negocio que dependen más de infraestructura tecnológica y de contenido que de mano de obra intensiva directamente contratada. La lección para cualquier análisis de política pública que compare “el tamaño” de estas empresas usando cifras de empleo es que la cifra reportada depende, de forma no trivial, de decisiones de diseño organizacional –qué actividades se internalizan como relación laboral formal y cuáles se externalizan hacia contratistas o socios independientes– que son, a su vez, objeto directo del debate regulatorio revisado en cada caso.

Un marco unificador: cuatro estrategias, un mismo aparato teórico

Vistas en conjunto, las cuatro empresas no compiten primordialmente por precio unitario en el sentido de la competencia perfecta de un curso de microeconomía elemental. Cada una explota, de forma dominante, un mecanismo distinto entre los revisados en las Sesiones 1 a 3 del curso –aunque, como se ha visto, ninguna se limita a uno solo–:

Empresa	Mecanismo dominante	Concepto (Sesión)	formal	Frontera regulatoria
Uber	Precios dinámicos en mercado de dos lados	Estructura de precios de Armstrong (S2)		Clasificación laboral
Amazon	Integración vertical + economías de alcance en datos/cómputo	Coase / Grossman-Hart-Moore (S3)		Autopreferencia algorítmica (FTC, 2023)
Mercado Libre	Integración <i>marketplace</i> -fintech ante fallo de información	Selección adversa tipo Akerlof (S2)	tipo	Riesgo de concentración crediticia
Netflix	Versionado / discriminación de precios de 2 ^{do} grado	Estructura de costos de bienes digitales (S1)		Uso de datos de comportamiento para segmentar

Table 4: Síntesis de los cuatro casos: mecanismo económico dominante, concepto formal asociado y principal frente regulatorio.

La regularidad más notable de esta comparación –y la que vale la pena discutir en el bloque aplicado de la sesión correspondiente– es que las cuatro fronteras regulatorias, pese a operar en industrias completamente distintas, comparten una misma estructura lógica: en los cuatro casos, la disputa no es si la empresa cobra un precio “demasiado alto” en el sentido convencional del daño al consumidor,

sino si la arquitectura de su plataforma –el diseño algorítmico de precios, de visibilidad, de acceso a crédito o de segmentación de usuarios– le permite capturar rentas que un mercado más fragmentado no le permitiría sostener. Esa es, precisamente, la pregunta que el aparato formal de las Sesiones 2 a 4 del curso está diseñado para ayudarle a formular –y, en la medida de lo posible, a responder– con rigor.

Bibliografía

Amazon.com, Inc. *Formulario 10-K 2025*. U.S. Securities and Exchange Commission. <https://ir.aboutamazon.com>

Cusumano, M. A., Gawer, A., y Yoffie, D. B. (2019). *The Business of Platforms*. Harper Business.

MercadoLibre, Inc. *Reporte de resultados del tercer trimestre de 2025* (Formulario 8-K). U.S. Securities and Exchange Commission.

Netflix, Inc. *Carta a accionistas, cuarto trimestre de 2025*. <https://ir.netflix.net>

Rochet, J.-C., y Tirole, J. (2003). Platform Competition in Two-Sided Markets. *Journal of the European Economic Association*, 1(4), 990–1029.

Stone, B. (2013). *The Everything Store: Jeff Bezos and the Age of Amazon*. Little, Brown and Company.

Uber Technologies, Inc. *Formulario 10-K 2025*. U.S. Securities and Exchange Commission. <https://investor.uber.com>

Varian, H. R. (1997/2000). Versioning Information Goods. En *Internet Publishing and Beyond*. MIT Press.

¿Qué tan grande es, en realidad, la economía digital?

La respuesta depende, casi por completo, de qué se decida medir

TIEMPO DE LECTURA ESTIMADO: 20–22 MINUTOS

Pregunte a cinco instituciones distintas qué tamaño tiene la economía digital mundial y obtendrá cinco respuestas distintas –no porque alguna esté “equivocada”, sino porque cada una mide un objeto conceptualmente diferente. El Banco Mundial estima que la economía digital representa alrededor del 15 % del producto mundial nominal en 2024, equivalente a unos 16 billones de dólares de un producto mundial de aproximadamente 108 billones. Forrester Research proyecta que la cifra alcanzará 16.5 billones de dólares –el 17 % del PIB mundial– hacia 2028, con una tasa de crecimiento anual compuesta del 7 % entre 2023 y 2028. La Organización de Cooperación Digital (DCO, por sus siglas en inglés) –un organismo intergubernamental– proyectó en 2026 que la cifra llegaría a 28 billones de dólares en ese mismo año, equivalentes a cerca del 22 % del PIB mundial. Y la Conferencia de las Naciones Unidas sobre Comercio y Desarrollo (UNCTAD) reporta que las ventas de comercio electrónico *empresarial* (B2B y B2C combinadas) alcanzaron 28 billones de dólares en su más reciente medición –una cifra similar en magnitud a la de la DCO, pero que mide algo distinto: el valor *bruto* de las transacciones, no el valor *agregado* atribuible a la actividad digital.

Σ Nota técnica: por qué las cifras no son comparables

La disparidad entre estimaciones no refleja, principalmente, desacuerdo empírico, sino una diferencia conceptual fundamental entre tres objetos de medición distintos: (i) el **valor agregado** generado por sectores intensivos en tecnologías digitales (el concepto más cercano a una contribución al PIB, y el que usan el Banco Mundial y Forrester); (ii) el **valor bruto de transacciones** habilitadas digitalmente, incluyendo comercio electrónico entre empresas (el concepto que reporta UNCTAD, que por definición excede varias veces al valor agregado, dado que una misma unidad de valor agregado puede generar múltiples transacciones intermedias a lo largo de una cadena de suministro); y (iii) el **gasto en transformación digital** de empresas que no son, en sí mismas, “digitales” (el concepto que usan consultoras como IDC). Comparar estas tres magnitudes sin ajustar por su definición es, en términos de la Sesión 1 del *syllabus*, análogo a comparar el costo medio $AC(Q)$ de dos firmas que usan definiciones distintas de Q .

Lo que sí converge: dirección y composición del crecimiento

Pese a la disparidad de niveles, las distintas fuentes coinciden en tres tendencias direccionales:

1. **La economía digital crece sistemáticamente más rápido que el producto mundial.** La DCO proyectó para 2026 un crecimiento del 9.5 % frente a un crecimiento del producto mundial cercano al 3 %; Forrester proyecta un crecimiento compuesto del 7 % anual entre 2023 y 2028 frente a un crecimiento nominal mundial de entre 5 y 6 %. En cualquier definición razonable, la participación digital del producto mundial es una función creciente del tiempo.
2. **La concentración geográfica es alta y persistente.** Casi dos terceras partes de la economía digital mundial, según Forrester, se originan en Estados Unidos y China; el resto se reparte, de forma de-

creciente, entre el Reino Unido, Japón, Alemania y Corea del Sur. Para las economías en desarrollo –incluida América Latina–, UNCTAD documenta que la participación de servicios digitalmente prestables en las exportaciones totales de servicios es de apenas 15 % en los países menos desarrollados, frente a más del 60 % en las economías avanzadas: la llamada *brecha digital* no se ha cerrado, y en algunas métricas de concentración de mercado se ha profundizado.

3. **La inteligencia artificial es, con diferencia, el componente de crecimiento más acelerado –y el más concentrado.** UNCTAD proyecta que el mercado mundial de inteligencia artificial alcanzará aproximadamente 5 billones de dólares hacia 2033, partiendo de una base muy inferior en 2024, lo que implica una de las tasas de crecimiento compuesto más altas dentro de cualquier subsegmento de la economía digital –y, simultáneamente, uno de los grados de concentración de mercado más altos, dado el número reducido de proveedores de cómputo a gran escala capaces de entrenar modelos de frontera (véase Sesión 4 del *syllabus*, sobre la estructura de costos de la predicción algorítmica).




Figure 4: Estimaciones institucionales del tamaño de la “economía digital”, 2024–2030. *Nota metodológica:* las barras no son directamente comparables entre sí –miden conceptos distintos, según se explica en el recuadro anterior–; la cifra de 2030 es una extrapolación ilustrativa de la trayectoria de Forrester (17 % del PIB mundial hacia 2028), no una proyección institucional publicada.

Proyecciones sectoriales hacia 2030: conectividad y datos

Más allá del valor agregado, las proyecciones de infraestructura ofrecen una medida complementaria –y menos disputada conceptualmente– del crecimiento esperado:

La economía digital de México, en el espejo de sus propios datos

Para un curso impartido en México, la pregunta de tamaño y proyección adquiere una dimensión adicional: ¿qué tan grande es la economía digital *mexicana*, específicamente? El Instituto Nacional de Estadística y Geografía (INEGI) publica, desde 2019, el Valor Agregado Bruto del Comercio Electrónico (VABCOEL) como su primera aproximación oficial a la medición de la economía digital nacional –una elección metodológica consciente que, como en el caso de UNCTAD, mide comercio electrónico como *proxy* más tratable que el concepto más amplio y difícil de delimitar de “economía digital”–. La serie histórica es reveladora: la participación del comercio electrónico en el PIB mexicano pasó de

Indicador	Nivel reciente	Proyección a 2029–2030
Dispositivos IoT conectados globalmente	~15–16 mil millones (2023)	38–39 mil millones
Conexiones 5G como % de conexiones móviles totales	~17 %	~54 % (5,300 millones de conexiones)
Envíos globales de <i>smartphones</i> (anual)	1.2 mil millones (2023)	Crecimiento moderado, mercado en maduración
Mercado mundial de IoT (valor)	\$690 mil M (2021)	\$1.85 billones (2028)

Table 5: Proyecciones de infraestructura digital hacia el final de la década (fuentes: UNCTAD, GSMA Intelligence).

apenas 3.0 % en 2013 a 5.0 % en 2018 y a 5.9 % en 2022 –una tasa de crecimiento de la participación más acelerada que la del PIB total en cualquiera de esos periodos, consistente con la tendencia mundial documentada por Forrester y la DCO–. El INEGI colabora, además, con las oficinas nacionales de estadística de Brasil, Colombia y Chile –coordinadas por la Comisión Económica para América Latina y el Caribe (CEPAL)– en un proyecto conjunto de medición mediante técnicas de *web scraping* de dominios nacionales (.mx, .br, .co, .cl), reconociendo que los métodos de encuesta tradicionales subestiman sistemáticamente la actividad de comercio electrónico informal o de plataformas transfronterizas –un problema de medición que, dada la importancia del comercio informal en la estructura económica latinoamericana, es cuantitativamente más severo en la región que en economías avanzadas.

Σ Nota técnica: por qué medir la economía digital de un país en desarrollo es más difícil

La brecha entre el valor agregado bruto de comercio electrónico reportado por el INEGI (5.9 % del PIB en 2022) y estimaciones alternativas –con frecuencia superiores, cuando incorporan gasto en publicidad digital, suscripciones a servicios de *streaming* extranjeros o actividad de plataformas de trabajo bajo demanda no formalmente registradas ante la autoridad fiscal– ilustra un problema de medición estructural: buena parte de la actividad digital transfronteriza (compras en plataformas extranjeras, pagos a plataformas de publicidad digital domiciliadas fuera del país) no se captura plenamente en los registros administrativos que alimentan las Cuentas Nacionales, incluso cuando el gasto del consumidor mexicano es plenamente real. Esta limitación es, en esencia, el mismo problema de *concentración geográfica de la oferta* documentado por UNCTAD para el conjunto de las economías en desarrollo: gran parte del valor generado por la actividad digital de un usuario mexicano puede registrarse, en las cuentas nacionales de otro país, como ingreso de exportación de servicios digitales.

El componente que crece más rápido: el gasto de capital en infraestructura de inteligencia artificial

Dentro del agregado de la economía digital, ningún componente ha crecido, entre 2023 y 2026, con la velocidad del gasto de capital (*capex*) destinado a construir infraestructura de cómputo para el entrenamiento e inferencia de modelos de inteligencia artificial. Amazon, cuyo caso se revisa con mayor detalle en la Lectura [3], destinó aproximadamente 131,800 millones de dólares a gasto de capital durante el año fiscal 2025 –equivalente a cerca del 18 % de sus ingresos totales de ese año–, en

gran medida vinculado a la construcción de centros de datos para servicios de inteligencia artificial generativa de AWS y a compromisos de cómputo con laboratorios de investigación externos. Cifras de magnitud comparable –aunque con variación considerable entre compañías y trimestres– se observan en el conjunto reducido de proveedores de infraestructura de nube a gran escala (*hyperscalers*) que dominan este segmento específico del mercado. Esta concentración del gasto de capital en un número reducido de actores es, precisamente, la manifestación más reciente de la estructura de costos revisada en la Sesión 1 del *syllabus* (F^* extraordinariamente alto, c^* decreciente con la escala): a diferencia de la fibra óptica de la década de 1990 –cuya sobreinversión, revisada en la Lectura [2], fue financiada en gran medida con deuda corporativa de empresas sin ingresos operativos significativos–, el actual ciclo de *capex* de infraestructura de IA se financia, en su mayor parte, con el flujo de caja operativo de empresas ya establecidas y rentables, una diferencia estructural que –como se discute con mayor detalle en la Lectura [2]– no elimina el riesgo de sobrecapacidad, pero sí modifica sustancialmente su mecanismo de transmisión hacia el resto de la economía en caso de una corrección de expectativas.

El problema conceptual más profundo: lo que el PIB no puede ver

Incluso si resolviéramos por completo el problema de atribución geográfica, subsistiría un problema de medición más fundamental –y más incómodo para cualquier economista formado en la tradición de cuentas nacionales–: buena parte del valor que los consumidores obtienen de la economía digital nunca se transa a un precio positivo, y por tanto nunca entra al cálculo del Producto Interno Bruto. Un mapa de navegación gratuito, un motor de búsqueda, una red social financiada por publicidad, o –cada vez más– un asistente de inteligencia artificial de uso gratuito generan un excedente del consumidor sustancial que el aparato de cuentas nacionales, diseñado en la década de 1930 para medir una economía de bienes transados a precios de mercado, no está en condiciones de capturar. Erik Brynjolfsson y sus coautores han propuesto, desde 2019, un indicador complementario –denominado informalmente “PIB-B” (*GDP-B*, por *benefits*)– que intenta monetizar ese excedente mediante experimentos de valoración contingente (cuánto tendría que pagársele a un usuario para que renunciara, por un mes, al uso de un servicio digital gratuito específico). Sus estimaciones preliminares sugieren que el excedente del consumidor generado por servicios digitales gratuitos podría equivaler, en algunas categorías, a varios puntos porcentuales adicionales de bienestar no capturado por el PIB convencional –una consideración crucial para cualquier lectura de las cifras de esta sección: **el tamaño de la economía digital medido en unidades monetarias de transacción es, casi con certeza, un límite inferior de su contribución real al bienestar**, no una medida completa de ella.

Ejercicio de discusión guiada

Preguntas para el bloque aplicado

- (i) Compare la trayectoria de la participación del comercio electrónico en el PIB mexicano (INEGI: 3.0 % en 2013, 5.9 % en 2022) con la trayectoria mundial reportada por Forrester (camino hacia 17 % del PIB mundial en 2028). ¿Qué factores estructurales –bancarización, logística de última milla, penetración de *smartphones*– podrían explicar la brecha, y qué tan rápido le parece razonable que se cierre? (ii) Proponga un experimento de valoración contingente sencillo –al estilo del “PIB-B”– para estimar el excedente del consumidor que usted personalmente obtiene de un servicio digital gratuito de su elección, y discuta las limitaciones de su propio diseño experimental.

Ante cualquier titular que anuncie “la economía digital vale X billones de dólares”, la pregunta metodológicamente correcta –y la que se espera que usted formule tras cursar la Sesión 1 de este curso– no es si la

cifra es “grande” o “pequeña”, sino: ¿qué está incluido en el denominador, y es comparable con el numerador que se usa para calcular la participación porcentual citada? La brecha entre 16 billones (Banco Mundial, valor agregado) y 28 billones (DCO/UNCTAD, valor de transacción bruto) no es un error de una u otra fuente: es la diferencia, familiar para cualquier economista, entre producto interno bruto y producto bruto de una economía con cadenas de valor extensas. La economía digital, en ese sentido, no es conceptualmente distinta de cualquier otro sector económico intensivo en insumos intermedios –sólo que la novedad tecnológica del sector genera, con frecuencia, menos escrutinio metodológico sobre cómo se agregan sus cifras.

Bibliografía

Brynjolfsson, E., Collis, A., Diewert, W. E., Eggers, F., y Fox, K. J. (2019). GDP-B: Accounting for the Value of New and Free Goods in the Digital Economy. *NBER Working Paper No. 25695*.

Comisión Económica para América Latina y el Caribe (CEPAL). *Proyecto Big Data para la Medición de la Economía Digital* (con INEGI, IBGE, DANE e INE Chile).

Digital Cooperation Organization (DCO). (2026). *Digital Economy Trends 2026 Report*.

Forrester Research. (2024). *Global Digital Economy Forecast, 2023 To 2028*.

GSMA Intelligence. (2023). *IoT Connections Forecast to 2030*.

Instituto Nacional de Estadística y Geografía (INEGI). *Valor Agregado Bruto del Comercio Electrónico (VABCOEL)*, serie histórica 2013–2022. <https://www.inegi.org.mx/temas/vabcoel/>

International Data Corporation (IDC). *Worldwide Digital Transformation Spending Guide* (serie).

International Monetary Fund (IMF). *Measuring the Digital Economy* (serie de notas técnicas del Departamento de Estadísticas).

UN Trade and Development (UNCTAD). (2024). *Digital Economy Report 2024: Shaping an Environmentally Sustainable and Inclusive Digital Future*.

UN Trade and Development (UNCTAD). (2025). *Facts and Figures: The Digital Economy* (nota técnica previa a UNCTAD16).

World Bank. (2019). *World Development Report 2019: The Changing Nature of Work* (capítulo sobre digitalización y estructura económica).

El algoritmo no es neutral: economía política del sesgo predictivo

Cuando la predicción barata de la Sesión 4 hereda –y amplifica– los sesgos del mundo que la entrena

TIEMPO DE LECTURA ESTIMADO: 20–22 MINUTOS

En mayo de 2016, el equipo de investigación de *ProPublica* publicó un análisis de COMPAS, un algoritmo comercial de evaluación de riesgo de reincidencia utilizado por tribunales de Florida para informar decisiones de libertad condicional. El hallazgo central: entre los acusados que *no* reincidieron en los dos años posteriores, los acusados negros tenían una probabilidad de haber sido clasificados erróneamente como “alto riesgo” casi el doble que la de los acusados blancos. La respuesta de la empresa desarrolladora fue, en cierto sentido, igualmente cierta: la tasa de acierto global del algoritmo –alrededor del 60%– era prácticamente idéntica para ambos grupos raciales. ¿Cómo puede un mismo algoritmo ser, simultáneamente, “justo” y “sesgado”? La respuesta a esa pregunta –que Kleinberg, Mullainathan y Raghavan (2016) formalizaron como un **resultado de imposibilidad**– es el punto de partida más riguroso, y menos ideológico, para entender la economía del sesgo algorítmico.

Tres nociones de equidad que no pueden satisfacerse simultáneamente

Kleinberg et al. (2016) demuestran que, salvo en casos triviales (predicción perfecta o tasas de base idénticas entre grupos), ningún clasificador puede satisfacer simultáneamente tres propiedades de equidad –cada una intuitivamente razonable por separado–:

1. **Calibración:** entre las personas a las que el algoritmo asigna una misma probabilidad de riesgo, la tasa real de reincidencia (o de la variable predicha) debe ser idéntica entre grupos.
2. **Paridad de tasas de falsos positivos:** entre las personas que *no* reincidirán, la probabilidad de haber sido erróneamente etiquetadas como alto riesgo debe ser idéntica entre grupos.
3. **Paridad de tasas de falsos negativos:** entre las personas que sí reincidirán, la probabilidad de haber sido erróneamente etiquetadas como bajo riesgo debe ser idéntica entre grupos.

COMPAS satisfacía la calibración (1) –lo que la empresa desarrolladora esgrimió en su defensa– pero no la paridad de falsos positivos (2) –lo que *ProPublica* documentó–. Cuando las tasas de base de la variable predicha difieren entre grupos –como ocurre con la tasa de reincidencia registrada, que refleja no sólo comportamiento sino también patrones históricos de vigilancia y arresto diferenciados–, es **matemáticamente imposible** satisfacer (1), (2) y (3) de forma simultánea. El sesgo algorítmico, en este sentido, no siempre es un error de programación corregible: con frecuencia es una elección –explícita o implícita– entre nociones de equidad en conflicto, tomada por quien diseña el sistema.

Σ Nota técnica: el sesgo como fallo de mercado, no sólo como fallo técnico

En el lenguaje de la Sesión 2 del *syllabus*, el sesgo algorítmico sistemático puede entenderse como una **externalidad negativa no internalizada**: el costo social de una predicción sesgada –sobre el grupo perjudicado por los falsos positivos, o subatendido por los falsos negativos– no recae, en la mayoría de los esquemas de incentivos actuales, sobre quien diseña o despliega el algoritmo, sino sobre terceros que no participaron en su diseño ni en su entrenamiento. Esta asimetría es,

precisamente, la que motiva el marco de “alineación como problema de agencia” que revisamos en la Sesión 4 (Gans, 2025): quien entrena el sistema de predicción (agente) no necesariamente asume el costo pleno de sus errores distribucionales sobre quienes deben confiar en sus recomendaciones (terceros afectados).

De dónde viene el sesgo: una taxonomía económica

Fuente de sesgo	Mecanismo	Caso ilustrativo
Sesgo de la variable proxy	El objetivo de predicción disponible (barato de medir) difiere sistemáticamente del objetivo real de interés (costoso de medir)	Un algoritmo hospitalario de gestión poblacional usaba el gasto histórico en salud como proxy de necesidad médica; dado que, condicional al mismo nivel de enfermedad, se gastaba históricamente menos en pacientes negros, el algoritmo subestimaba sistemáticamente su necesidad real (Obermeyer, Powers, Vogeli y Mullainathan, 2019, <i>Science</i>)
Sesgo de representación en los datos de entrenamiento	Los grupos subrepresentados en el conjunto de entrenamiento generan estimaciones de menor precisión para ese grupo	<i>Gender Shades</i> (Buolamwini y Gebru, 2018): los conjuntos de datos usados para entrenar clasificadores comerciales de género facial estaban compuestos en un 79.6–86.2 % por personas de piel clara
Sesgo histórico incorporado en la etiqueta	El algoritmo aprende a replicar decisiones humanas pasadas que ya incorporaban discriminación	Amazon discontinuó en 2018 un prototipo interno de selección de currículos que había aprendido, de una década de contrataciones históricas dominadas por hombres, a penalizar currículos que incluían la palabra “mujeres” (p.ej., “capitana del club de ajedrez de mujeres”)
Sesgo de despliegue diferencial	El mismo error absoluto de predicción tiene consecuencias distintas según el contexto de uso de cada grupo	Sistemas de reconocimiento facial con tasas de error agregadas bajas pero con error concentrado en subgrupos específicos, desplegados de forma más intensiva en contextos de vigilancia que afectan desproporcionadamente a esos mismos subgrupos

Table 6: Taxonomía de fuentes económicas y técnicas del sesgo algorítmico, con casos documentados.

• Caso: el algoritmo de salud poblacional de Obermeyer et al. (2019)

El estudio de Obermeyer, Powers, Vogeli y Mullainathan, publicado en *Science*, examinó un algoritmo comercial utilizado para identificar a pacientes con necesidades de salud complejas que se beneficiarían de programas de atención adicional –un sistema que, en conjunto, afecta las de-

cisiones de atención de aproximadamente 200 millones de personas al año en Estados Unidos—. El algoritmo usaba el *gasto histórico en salud* como variable de sustitución (*proxy*) de la necesidad médica real, bajo el supuesto –razonable en apariencia– de que gastar más en un paciente refleja que ese paciente está más enfermo. El problema: por razones de acceso desigual al sistema de salud, los pacientes negros generaban históricamente menos gasto que los pacientes blancos *con el mismo nivel real de enfermedad*. El resultado fue que, a un mismo puntaje de riesgo asignado por el algoritmo, los pacientes negros estaban –en promedio– considerablemente más enfermos que los pacientes blancos. Corregir el sesgo –sustituyendo el gasto histórico por indicadores clínicos directos de severidad– habría más que duplicado la proporción de pacientes negros identificados para recibir atención adicional: del 17.7 % al 46.5 %, sin necesidad de introducir la raza como variable explícita del modelo. El sesgo, en este caso, no provino de una variable racial explícita –que ni siquiera estaba entre los insumos del modelo–, sino de una variable *proxy* aparentemente neutral cuya relación con el objetivo real de predicción difería sistemáticamente entre grupos.

El dilema equidad–precisión y su representación formal

Buena parte del debate de política pública sobre inteligencia artificial asume, implícitamente, que “corregir el sesgo” es una operación sin costo. La literatura de aprendizaje automático documenta, en cambio, que –salvo en casos específicos, como el reformulado por Obermeyer et al. (2019), donde corregir el sesgo también mejoró la precisión– suele existir una **disyuntiva** entre la precisión predictiva agregada de un modelo y el grado de paridad estadística que impone entre grupos, particularmente cuando las restricciones de equidad se imponen *ex post* sobre un modelo ya optimizado únicamente para precisión.




Figure 5: Representación estilizada de la disyuntiva equidad–precisión: la forma exacta de la curva depende de la estructura de datos subyacente; en el caso de Obermeyer et al. (2019), la curva resultó prácticamente plana –e incluso mejoró la precisión clínicamente relevante–, precisamente porque el sesgo original provenía de una variable *proxy* defectuosa, no de una disyuntiva estadística inherente.

¿Por qué las firmas no corrigen el sesgo por sí solas? Una lectura de incentivos

Si corregir el sesgo algorítmico frecuentemente no implica –como demuestra el caso de Obermeyer et al. (2019)– un costo en términos de precisión agregada, cabe preguntarse por qué no es una práctica generalizada por defecto. La respuesta, desde la óptica de la Sesión 2 del curso, es una asimetría clásica entre costo privado y costo social. Auditar un sistema de predicción por sesgo distribucional

requiere –de forma no trivial– datos desagregados por grupo protegido, personal técnico especializado en métricas de equidad, y –con frecuencia– aceptar una reducción marginal en la métrica de precisión agregada que la firma reporta a sus propios accionistas o reguladores sectoriales. El costo de *no* auditar, en cambio, recae mayoritariamente sobre los individuos mal clasificados –el defendido erróneamente etiquetado de alto riesgo, el paciente no identificado para atención adicional, el candidato descartado por un sesgo de género heredado del historial de contratación–, quienes rara vez tienen la capacidad de organizarse para internalizar ese costo de vuelta hacia quien diseñó el sistema. Formalmente, denotando $\pi(\text{sesgo})$ el beneficio privado de una firma que no corrige el sesgo de su sistema de predicción y $W(\text{sesgo})$ el bienestar social bajo ese mismo sesgo:

$$\frac{\partial \pi}{\partial (\text{corrección de sesgo})} \approx 0 \text{ o incluso } < 0 \quad (\text{costo de auditoría}), \quad \frac{\partial W}{\partial (\text{corrección de sesgo})} > 0,$$

la divergencia entre ambas derivadas –el mismo tipo de brecha entre beneficio privado y beneficio social que explica, en la Sesión 2, la subinversión en infraestructura de red de bien público (Lectura [1], Acto I)– es la que justifica, desde una lógica puramente de eficiencia y no sólo de equidad distributiva, la intervención regulatoria mediante auditorías obligatorias para sistemas de alto riesgo.

El sesgo en los mercados que ya conocemos: crédito y trabajo digital

El sesgo algorítmico no es un fenómeno confinado a la justicia penal, la salud o el reconocimiento facial: aparece, con la misma estructura formal, en dos de los mercados revisados en la Lectura [3] de este cuadernillo. En la calificación crediticia algorítmica –el mecanismo central del argumento de Mercado Libre y Mercado Pago revisado en esa lectura–, cualquier modelo entrenado con datos históricos de otorgamiento de crédito hereda, por construcción, los patrones de exclusión financiera históricos de la región: si históricamente se otorgó menos crédito formal a mujeres, a trabajadores del sector informal o a residentes de zonas geográficas específicas –no por menor solvencia real, sino por menor acceso histórico a la banca tradicional–, un modelo que aprenda de esos datos corre el riesgo de reproducir esa exclusión bajo la apariencia de una decisión “objetiva” basada en datos, exactamente el mismo mecanismo de sesgo de la variable histórica documentado para el caso de contratación de Amazon. La diferencia –y la razón por la que la industria fintech latinoamericana defiende con frecuencia sus modelos alternativos de calificación crediticia (basados en datos transaccionales de comercio electrónico, en lugar de historial bancario formal)– es que, en principio, un modelo entrenado sobre una variable menos contaminada por exclusión histórica (el comportamiento de compra, en lugar del historial de acceso a crédito bancario) podría –si se audita correctamente– *reducir* el sesgo de exclusión existente en lugar de perpetuarlo. Si esa promesa se cumple en la práctica, y no sólo en el discurso corporativo, es precisamente una pregunta empírica que exige el mismo tipo de auditoría de paridad que ProPublica aplicó a COMPAS.

En los mercados de trabajo digital (Uber y plataformas análogas, Lectura [3]), la literatura reciente ha documentado patrones de asignación algorítmica de tarifas y de solicitudes de viaje que –sin que exista evidencia de intención discriminatoria explícita por parte de la plataforma– pueden generar disparidades de ingreso correlacionadas con la zona geográfica de operación del conductor, un patrón estructuralmente idéntico al sesgo de *proxy* geográfico documentado en otros contextos de calificación algorítmica de riesgo.

Panorama regulatorio comparado

Un problema nuevo con la misma estructura: el sesgo en la IA generativa

Los sistemas de inteligencia artificial generativa –modelos de lenguaje y generadores de imágenes de uso masivo desde 2022– han hecho visible una variante adicional del mismo problema estructural,

Jurisdicción	Enfoque regulatorio	Mecanismo central
Unión Europea	Regulación <i>ex ante</i> basada en niveles de riesgo (Ley de IA, Reglamento (UE) 2024/1689)	Auditoría obligatoria y evaluación de conformidad previa al despliegue para sistemas de “alto riesgo” (crédito, empleo, justicia, salud)
Estados Unidos	Enfoque sectorial fragmentado, sin ley federal integral de IA a la fecha de esta lectura	Aplicación de leyes antidiscriminación sectoriales existentes (crédito, vivienda, empleo) a sistemas algorítmicos, más órdenes ejecutivos y guías no vinculantes
México y América Latina	Marco en desarrollo; ausencia de legislación integral específica de IA	Aplicación de la Ley Federal de Protección de Datos Personales y de principios generales de no discriminación constitucional; propuestas legislativas en discusión

Table 7: Panorama comparado de enfoques regulatorios frente al sesgo algorítmico (situación aproximada a 2026).

esta vez a escala de estereotipo cultural agregado en lugar de decisión individual sobre una persona específica. Investigaciones independientes han documentado que los generadores de imágenes comerciales, entrenados sobre volúmenes masivos de contenido extraído de internet, tienden a reproducir –y, en algunos casos, a amplificar respecto a la distribución real del mundo laboral– asociaciones estereotípicas entre ocupaciones y género o entre ocupaciones y grupo étnico presente en sus datos de entrenamiento: solicitar la imagen de un “director ejecutivo” o de un “ingeniero” produce, con mucha mayor frecuencia que la que reflejaría la composición demográfica real de esas profesiones, representaciones de hombres; solicitar la imagen de un “asistente administrativo” o un “trabajador doméstico” invierte sistemáticamente ese patrón. La causa formal es idéntica a la de los tres casos revisados en la Sección anterior –sesgo de representación en los datos de entrenamiento (*Gender Shades*) combinado con sesgo histórico incorporado en el corpus de origen (el caso de Amazon)–, pero la escala de despliegue –cientos de millones de usuarios generando contenido de forma cotidiana– multiplica el efecto agregado de cada sesgo individual sobre la percepción cultural compartida, un canal de propagación que no existía –o existía a una escala mucho menor– en los sistemas de decisión individual (crédito, empleo, salud) que dominan la literatura académica citada hasta aquí.

Frente a este panorama, la literatura técnica de aprendizaje automático distingue tres familias de intervención de mitigación, cada una con implicaciones económicas distintas sobre quién asume el costo de la corrección:

- Intervención sobre los datos (*pre-processing*):** reponderar o balancear el conjunto de entrenamiento antes de ajustar el modelo, de forma que ningún subgrupo esté sistemáticamente subrepresentado –la estrategia implícita en el conjunto de datos balanceado que Buolamwini y Gebru (2018) construyeron precisamente para *evaluar* el sesgo de los sistemas comerciales existentes–.
- Intervención sobre el algoritmo (*in-processing*):** incorporar restricciones de equidad –por ejemplo, paridad aproximada de tasas de falsos positivos entre grupos– directamente en la función objetivo que el modelo optimiza durante el entrenamiento, aceptando explícitamente la disyuntiva equidad–precisión de la Figura 5 cuando ésta existe.

3. **Intervención sobre las salidas (*post-processing*):** ajustar los umbrales de decisión de un modelo ya entrenado de forma diferenciada por grupo, sin modificar el modelo mismo –la estrategia más barata de implementar, pero también la más frágil ante escrutinio legal, dado que introduce explícitamente el atributo protegido como variable de decisión, algo que varias jurisdicciones restringen incluso cuando el propósito es corregir un sesgo preexistente.

Ninguna de las tres familias de intervención es gratuita ni neutral: todas requieren que alguien –el desarrollador del modelo, el regulador, o un tercero auditor– decida, de antemano, cuál de las nociones de equidad en conflicto documentadas por Kleinberg et al. (2016) merece prioridad en un contexto de aplicación específico. Esa decisión, en última instancia, no es una decisión técnica sino una decisión de política pública y de valores sociales –razón adicional por la que la auditoría algorítmica, revisada en el panorama regulatorio comparado que sigue, no puede delegarse por completo en la propia industria que produce el sistema a auditar.

La Ley de Inteligencia Artificial de la Unión Europea (2024) adopta, precisamente, un enfoque basado en riesgo que exige auditorías de sesgo más estrictas para sistemas de “alto riesgo” –contratación laboral, calificación crediticia, justicia penal, salud– que para aplicaciones de bajo riesgo, reconociendo implícitamente que el costo económico y social de un error de predicción varía sistemáticamente según el contexto de despliegue, no según una propiedad intrínseca del algoritmo. Desde la óptica del marco de Gans (2025) revisado en la Sesión 4, la regulación de sesgo algorítmico puede entenderse como un mecanismo para **realinear los incentivos** entre quien produce la predicción (con información imperfecta sobre sus efectos distribucionales) y quien sufre las consecuencias de un error de clasificación –un problema de agencia con una solución de mercado incompleta mientras no exista responsabilidad legal clara ni auditoría obligatoria., precisamente, un enfoque basado en riesgo que exige auditorías de sesgo más estrictas para sistemas de “alto riesgo” –contratación laboral, calificación crediticia, justicia penal, salud– que para aplicaciones de bajo riesgo, reconociendo implícitamente que el costo económico y social de un error de predicción varía sistemáticamente según el contexto de despliegue, no según una propiedad intrínseca del algoritmo. Desde la óptica del marco de Gans (2025) revisado en la Sesión 4, la regulación de sesgo algorítmico puede entenderse como un mecanismo para **realinear los incentivos** entre quien produce la predicción (con información imperfecta sobre sus efectos distribucionales) y quien sufre las consecuencias de un error de clasificación –un problema de agencia con una solución de mercado incompleta mientras no exista responsabilidad legal clara ni auditoría obligatoria.

El sesgo algorítmico no es, casi nunca, el resultado de una intención discriminatoria explícita: es, con mucha más frecuencia, el resultado de optimizar honestamente una variable *proxy* barata de medir (gasto en salud, historial de contrataciones, tasa de arresto) que difiere sistemáticamente, entre grupos, de la variable que realmente importa (necesidad médica, capacidad laboral, comportamiento futuro). Distinguir entre ambas –y entender el costo de hacerlo– es, en última instancia, un problema de diseño de mecanismos, no sólo de ética aplicada.

Bibliografía

- Angwin, J., Larson, J., Mattu, S., y Kirchner, L. (2016). Machine Bias. *ProPublica*, 23 de mayo de 2016.
- Barocas, S., y Selbst, A. D. (2016). Big Data's Disparate Impact. *California Law Review*, 104(3), 671–732.

Buolamwini, J., y Gebru, T. (2018). Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification. *Proceedings of Machine Learning Research (Conference on Fairness, Accountability, and Transparency)*, 81, 77–91.

European Commission (2024). *Regulation (EU) 2024/1689 Laying Down Harmonised Rules on Artificial Intelligence (Artificial Intelligence Act)*.

Kleinberg, J., Mullainathan, S., y Raghavan, M. (2016). Inherent Trade-Offs in the Fair Determination of Risk Scores. *Proceedings of the 8th Innovations in Theoretical Computer Science Conference (ITCS)*.

Obermeyer, Z., Powers, B., Vogeli, C., y Mullainathan, S. (2019). Dissecting Racial Bias in an Algorithm Used to Manage the Health of Populations. *Science*, 366(6464), 447–453.

O’Neil, C. (2016). *Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy*. Crown.

Dastin, J. (2018). Amazon Scraps Secret AI Recruiting Tool That Showed Bias Against Women. *Reuters*, 10 de octubre de 2018.

El economista jefe, reencarnado: el auge del CDO con formación económica

En 2026, el cargo que decide cuánta predicción comprar y cuánto juicio conservar ya no es un cargo técnico, sino uno microeconómico

TIEMPO DE LECTURA ESTIMADO: 20–22 MINUTOS

En enero de 2026, un artículo de opinión en *Forbes* sobre las tendencias de la alta dirección predijo, sin ironía aparente, que las organizaciones necesitarían pronto un director de inteligencia artificial (*Chief AI Officer*) para adopción y productividad, un director de seguridad de inteligencia artificial (*Chief AI Security Officer*) para riesgo y gobernanza, y que el tradicional director digital (*Chief Digital Officer*, CDO) regresaría –palabras textuales– “por soberanía, no por analítica”. Quien intente hoy trazar un organigrama limpio de la función digital de una empresa se encuentra, en cambio, con una proliferación de títulos –CDO, CDAO, CAIO, CDIO– que se superponen, compiten y con frecuencia describen, con distinto nombre, exactamente el mismo trabajo. Esta última lectura complementaria del curso no pretende resolver esa confusión terminológica –tarea, en el mejor de los casos, efímera–, sino argumentar algo más específico y más útil para usted como estudiante de economía: que, detrás de la etiqueta que finalmente prevalezca, el contenido sustantivo del cargo se ha desplazado hacia un problema que la teoría microeconómica de este curso está diseñada para resolver, y que explica por qué un número creciente de organizaciones busca, deliberadamente, economistas para ocuparlo.

De analista a arquitecto: una breve historia del cargo

El Director de Datos (*Chief Data Officer*) nació, en su primera encarnación, como una función defensiva. Antes de la crisis financiera de 2008–2009, el cargo era prácticamente inexistente; hacia 2012, apenas 12 % de las firmas –mayoritariamente instituciones financieras de gran escala, presionadas por requisitos regulatorios de gestión de riesgo de datos– habían nombrado a alguien en esa posición. El mandato original era, en esencia, de cumplimiento y gobernanza: garantizar la calidad, consistencia y trazabilidad de los datos que la firma ya poseía, no generar nuevo valor a partir de ellos. Como resume certeramente un análisis reciente del sector, el CDO de esa primera generación era, con frecuencia, “un CIO en miniatura” –una función técnica subordinada, sin asiento propio en la mesa de decisiones estratégicas.

Ese mandato se ha transformado radicalmente en los últimos catorce años. Para 2026, según la encuesta ejecutiva de referencia del sector (2026 AI & Data Leadership Executive Benchmark Survey), 90 % de las compañías reportan haber nombrado formalmente a un director de datos y/o inteligencia artificial, y 69.8 % considera que el cargo está “bien establecido” dentro de su estructura de gobierno corporativo –una cifra que ha crecido más de veinte puntos porcentuales en apenas un año, y que duplica la de 2023–. Las dos terceras partes de quienes ocupan el cargo reportan directamente al director general (CEO), frente a una minoría que, hace apenas una década, se ubicaba un nivel por debajo, subordinada al director de mercadotecnia o al director de tecnología. El gasto mundial en transformación digital, que sustenta este mandato ampliado, se proyecta por encima de 3.9 billones de dólares –una cifra del mismo orden de magnitud que las estimaciones institucionales del tamaño de la economía digital revisadas en la Lectura complementaria [4] de este cuadernillo.




Figure 6: Proporción de empresas con un Director de Datos y/o Inteligencia Artificial formalmente nombrado, 2012–2026 (puntos de 2012 y 2026 verificados mediante encuestas del sector; trayectoria intermedia ilustrativa).

2026: el año en que el mandato digital se fragmentó

Ese crecimiento en la adopción del cargo coexiste, paradójicamente, con una crisis de definición sobre lo que el cargo debe *hacer*. Un análisis del sector publicado a inicios de 2026 se pregunta abiertamente si el CDO “está muriendo o está siendo redefinido”, documentando que cerca de 70 % de las empresas están reestructurando o redefiniendo su modelo de liderazgo de datos, en gran medida como respuesta a la irrupción de un título competidor: el Director de Inteligencia Artificial (*Chief AI Officer*, CAIO), una posición que –según algunas estimaciones del mercado ejecutivo– ya percibe compensaciones en el rango de 250,000 a más de 400,000 dólares anuales, comparable o superior a la del CDO tradicional. La tensión no es meramente semántica: refleja una pregunta de diseño organizacional genuina –¿debe la responsabilidad de la infraestructura de datos, la estrategia de IA generativa, la gobernanza algorítmica y la transformación de procesos de negocio residir en una sola persona, o fragmentarse en mandatos especializados?–, la misma pregunta de integración vertical frente a especialización que la Sesión 3 del curso formaliza mediante el aparato de Coase y de las economías de alcance.

Un indicio revelador de esta inestabilidad de mandato es la tenencia promedio del cargo: mientras el director general (CEO) permanece, en promedio, 7.6 años en el cargo dentro de las empresas del índice S&P 500, y el director jurídico 6.1 años, la tenencia promedio de un director de datos o digital ronda apenas 30 meses –dos años y medio–, una de las más cortas de toda la alta dirección. Como observa un analista de contratación ejecutiva especializado en el sector, la mayoría de las salidas anticipadas no se explican por una mejor oferta en otra empresa, sino porque “el mandato se evapora silenciosamente”: el cargo se crea con expectativas de transformación amplia, pero sin el presupuesto, la autoridad de

Título	Mandato típico en 2026	Tensión de diseño organizacional
CDO (Chief Digital Officer)	Estrategia digital de extremo a extremo: canales, experiencia de cliente, integración de IA en procesos de negocio	Mandato amplio, pero con frecuencia sin presupuesto ni autoridad de decisión proporcional (véase discusión de tenencia más abajo)
CDAO (Chief Data & AI Officer)	Gobernanza de datos, calidad, cumplimiento, además de estrategia de IA a escala de producción	En la mayoría de las empresas en 2026, un mismo ejecutivo cubre ambos mandatos (datos + IA) por razones de economía de alcance
CAIO (Chief AI Officer)	Adopción y productividad de IA generativa; retorno sobre inversión de proyectos de IA	Se justifica como cargo separado solo cuando la IA constituye una apuesta de ingresos lo suficientemente grande como para merecer presupuesto, autoridad y disputas propias
CDIO / CIO ampliado	Infraestructura tecnológica, ciberseguridad, y –cada vez más– gobernanza de IA y evaluación de proveedores	Absorbe funciones antes exclusivas del CDO conforme la IA se vuelve infraestructura de uso general, no una iniciativa aislada

Table 8: Panorama comparado de mandatos de la alta dirección digital en 2026 y sus tensiones de diseño organizacional asociadas.

decisión o el respaldo continuo del CEO necesarios para ejecutarlo –un problema, en el lenguaje de la Sesión 3 del curso, de **derechos de control residual** mal especificados desde el diseño mismo del puesto.




Figure 7: Tenencia promedio por cargo entre ejecutivos de la alta dirección de empresas del índice S&P 500 (2026). El CDO/CDAO exhibe la tenencia más corta del conjunto.

Por qué un economista piensa exactamente como debería pensar un CDO

Frente a esta inestabilidad de mandato, una tesis específica ha ganado tracción entre firmas de búsqueda de ejecutivos y analistas del sector: que la formación en economía –no en ciencia de datos, no en ingeniería, no en administración de empresas genérica– constituye una ventaja comparativa distintiva para ocupar el cargo. Un análisis de 2024, ampliamente citado en la literatura de gestión de datos, argumenta que “la formación económica dota al CDO de un marco robusto para crear valor y alinear las iniciativas de datos con los objetivos operativos y de negocio de la organización”, y que la evidencia disponible muestra que los CDO con formación económica tienen, en promedio, mejores resultados que sus pares con formación puramente técnica.

La razón formal –que este curso le ha dado las herramientas para articular con precisión, en lugar de aceptarla como una afirmación de sentido común– tiene al menos cuatro componentes:

1. **Inferencia causal como disciplina central, no como herramienta ocasional.** La pregunta que domina el trabajo cotidiano de un CDO –¿este cambio de producto, de precio o de algoritmo *causó* la mejora observada, o solo la acompañó?– es, precisamente, la pregunta que la econometría aplicada y el diseño experimental (*A/B testing*) han formalizado durante seis décadas. No es casualidad que Hal Varian –coautor, junto con Carl Shapiro, de *El dominio de la información*, el texto reseñado al inicio del *syllabus* de este curso– se convirtiera en 2002 en el primer economista académico en ocupar el cargo de economista en jefe de una gran empresa tecnológica (Google), ni que Susan Athey (Microsoft), Preston McAfee (Yahoo!, Microsoft, Google) y, más recientemente, Patrick Bajari –quien ha construido en Amazon el equipo de más de 150 economistas con doctorado, la mayor concentración de economistas empleados fuera de la academia en el mundo– hayan seguido una trayectoria similar.
2. **Diseño de mecanismos y de mercados.** Las subastas de publicidad digital, los sistemas de reputación de *marketplaces* (Sesión 2, Lectura [3]) y las estructuras de precios de plataformas de dos lados (Armstrong, 2006) son, todos, problemas de diseño de mecanismos –el subcampo de la microeconomía en el que Varian, Athey y McAfee se formaron académicamente antes de incorporarse a la industria.
3. **Razonamiento de estática comparativa bajo restricciones presupuestarias.** La pregunta que enfrenta cualquier CDO en 2026 –¿dónde invertir el siguiente millón de dólares de presupuesto de datos e IA: en infraestructura de cómputo, en talento humano especializado, en gobernanza, o en adquisición de datos de terceros?– es formalmente un problema de optimización restringida con precios relativos cambiantes, exactamente el aparato que este curso ha desarrollado en cada una de sus cuatro sesiones.
4. **Comodidad intelectual con el trade-off, no con el eslogan.** A diferencia de un discurso puramente tecnológico –que tiende a presentar la adopción de IA como un imperativo sin matices–, la formación económica entrena a evaluar sistemáticamente costos de oportunidad, efectos de equilibrio general y externalidades no internalizadas (Sesión 2, 2.3; Sesión 4, 3.3) antes de comprometer capital organizacional a una iniciativa específica.

• Caso: del economista en jefe al director de datos — una genealogía

La trayectoria de Hal Varian –de profesor de teoría de la organización industrial en Berkeley, a economista en jefe de Google desde 2002, pasando por la coautoría del texto fundacional de este curso publicado en 1999– anticipa, con casi un cuarto de siglo de anticipación, el argumento

central de esta lectura: que la ventaja competitiva de un economista dentro de una organización tecnológica no reside en su capacidad de programar o de administrar infraestructura –tareas para las que existen especialistas mejor formados–, sino en su capacidad de traducir preguntas de negocio ambiguas (“¿deberíamos lanzar esta función?”, “¿cómo deberíamos fijar el precio de este nuevo nivel de suscripción?”) en problemas de optimización con supuestos explícitos, contrastables empíricamente y sujetos a estática comparativa. El cargo de “economista en jefe” de 2002 y el cargo de “director de datos e inteligencia artificial” de 2026 no son, en sustancia, cargos distintos: son la misma función, rebautizada dos veces conforme la tecnología subyacente –de las subastas de búsqueda a los modelos de predicción a gran escala– ha cambiado de nombre a su alrededor.

El CDO como gestor de la frontera entre predicción y juicio

La formulación más precisa del mandato del CDO de 2026 –y la que cierra el círculo con el marco central de la Sesión 4 de este curso– es la siguiente: su función sustantiva es **decidir, en nombre de la organización, dónde se traza la frontera entre predicción algorítmica y juicio humano** en cada proceso de decisión relevante, y gestionar activamente el desplazamiento de esa frontera conforme el costo de la predicción – c_P en la notación de Agrawal, Gans y Goldfarb (2018) y de Gans (2025)– continúa cayendo.

Retome el problema de optimización revisado en la Sesión 4 del *syllabus*:

$$\min_{P, J} c_P \cdot P + c_J \cdot J \quad \text{s.a.} \quad Q(P, J) = \bar{Q},$$

Cada una de las decisiones características del cargo –¿qué procesos automatizar primero?, ¿qué modelos de IA generativa desplegar en producción y con qué supervisión humana?, ¿qué datos adquirir, construir o comprar a un proveedor externo?– es una instancia concreta de este problema abstracto, aplicada proceso por proceso a lo largo de toda la organización. Un CDO con formación técnica pero sin entrenamiento económico tiende a optimizar cada instancia de forma aislada, maximizando la precisión predictiva del modelo específico que tiene enfrente; un CDO con formación económica reconoce que el problema relevante es de asignación de un presupuesto de predicción *across* toda la organización –sujeto a rendimientos marginales decrecientes en cada proceso individual–, exactamente el tipo de problema de asignación de recursos escasos entre usos alternativos que constituye el objeto de estudio más elemental, y más duradero, de la disciplina económica.

Esta reformulación explica también por qué la inestabilidad de mandato documentada en la Figura 7 es, en cierto sentido, estructural y no meramente circunstancial: un CDO cuyo trabajo consiste en desplazar continuamente la frontera predicción–juicio a través de toda la organización inevitablemente reasigna autoridad de decisión –antes ejercida por gerentes de línea mediante juicio discrecional– hacia sistemas centralizados de predicción, generando fricción organizacional persistente que ningún rediseño de organigrama puede eliminar por completo, solo gestionar.

Una nota sobre el talento económico digital en México

La demanda de este perfil híbrido –formación económica combinada con fluidez técnica– no es exclusiva de las grandes tecnológicas estadounidenses revisadas en el caso anterior. El sector de tecnología inmobiliaria (*PropTech*) mexicano, por ejemplo, exige de forma creciente la misma combinación de rigor microeconómico –para modelar demanda de vivienda, precios hedónicos y dinámicas de mercado regional– y capacidad de traducir esos modelos en arquitecturas de datos y sistemas de decisión algorítmica operables a escala. Un patrón análogo es previsible en el sector financiero y de comercio electrónico de la región: en plataformas con la estructura de negocio de Mercado Libre y su brazo

fintech Mercado Pago (Lectura complementaria [3]), el problema central de sus áreas de datos y riesgo –calibrar la frontera entre modelos predictivos automatizados y revisión humana discrecional en decisiones de crédito– es, precisamente, una instancia del problema formal desarrollado en la sección anterior de esta lectura, con independencia de qué perfil profesional específico ocupe hoy ese rol en cada organización. Para el estudiante de este curso que se pregunte si estas herramientas tienen aplicación fuera de Silicon Valley, la respuesta –visible ya en el ecosistema digital mexicano y latinoamericano estudiado a lo largo de este cuadernillo– es afirmativa y, cada año, más extendida.

Una nota final para quien se pregunte si este es el camino profesional correcto

Para el estudiante de economía que cursa esta materia, la conclusión práctica de esta lectura no es que un doctorado en economía sea condición suficiente para ocupar la dirección digital de una organización –la evidencia sugiere, más bien, que la combinación de formación económica *con* fluidez técnica suficiente para dialogar con equipos de ingeniería y ciencia de datos es la que produce los mejores resultados documentados–. La conclusión es más modesta y, a la vez, más útil: el aparato conceptual desarrollado a lo largo de las cuatro sesiones de este curso –estructura de costos de bienes de información, externalidades de red, fallos de mercado, integración vertical, y la descomposición de la decisión en predicción y juicio– no es un ejercicio académico separado de la práctica profesional de la economía digital, sino, cada vez con mayor literalidad, la descripción de trabajo de uno de los cargos de mayor crecimiento –y de mayor rotación– de la alta dirección corporativa contemporánea.

Ejercicio de discusión guiada

Preguntas para el bloque aplicado

(i) Con base en la Tabla 8 de esta lectura, discuta si su organización –o una organización que conozca bien– se beneficiaría de fragmentar el mandato digital en CDO, CDAO y CAIO por separado, o de consolidarlo en un solo cargo. Aplique explícitamente el criterio de economías de alcance de la Sesión 3 ($C(q_1 + q_2) \leq C(q_1) + C(q_2)$) a su respuesta. (ii) Elabore, para un proceso de decisión específico de su elección (contratación, precios, control de calidad, atención a clientes), un diagnóstico breve de dónde se ubica hoy la frontera entre predicción y juicio, y qué movimiento de esa frontera recomendaría a un CDO durante los próximos dos años, justificando su recomendación con el aparato de la Sesión 4.

Bibliografía

- Agrawal, A., Gans, J., y Goldfarb, A. (2018). *Prediction Machines: The Simple Economics of Artificial Intelligence*. Harvard Business Review Press.
- Athey, S., y Luca, M. (2019). Economists (and Economics) in Tech Companies. *Journal of Economic Perspectives*, 33(1), 209–230.
- Christian & Timbers. (2026). *Chief Digital Officer Executive Search Guide for 2026*.
- Gans, J. S. (2025). *The Microeconomics of Artificial Intelligence*. MIT Press.
- Heidrick & Struggles. (2023). *Digital and Technology Leadership Study*.
- KORE1. (2026). *How to Hire a Chief Data Officer: 2026 Guide*.
- Prospeo. (2026). *C-Suite Titles: Complete Guide to Roles & Hierarchy*.

Schmarzo, B. (2024). Talking to a CDO? Think Like an Economist. *Data Science Central* (republished por Orbition Group).

Shapiro, C., y Varian, H. R. (2000). *El dominio de la información: una guía estratégica para la economía de la red*. Antoni Bosch Editor.

2026 AI & Data Leadership Executive Benchmark Survey. Wavestone / NewVantage Partners.

— Fin de las lecturas complementarias —